

Rapport 2 — Expansion de l'espace d'action : cultiver + nombre de saisons

Suite du premier rapport. On ajoute deux leviers de décision et on mesure l'effet sur le revenu.

1. Contexte

Le premier rapport établissait un pipeline MARL fonctionnel avec une action Box(4) (irrigation, quantité d'irrigation, pesticide, fertilisation). Conclusion : l'optimum était une politique **quasi-constante** (BAU intensif) — il n'y avait presque rien à apprendre, et l'entraînement dérivait.

Hypothèse de cette étape : **ajouter des leviers à fort impact** pourrait (a) rendre le problème réellement *apprenable*, et (b) révéler de meilleures stratégies. On ajoute les deux fonctions de changement de pratique du collègue restées inutilisées :

- `change_rice_cultivar` — riz **standard (OM5451)** vs **premium (ST25)** ;
- `change_number_seasons` — calendrier **2** vs **3** saisons.

2. Changements

2.1 Espace d'action — Box(4) → Box(6)

dim	levier	décodage (seuil 0.5)
a[0]	irrigation	CF / AWD
a[1]	quantité irrigation	profondeur CF / seuil AWD
a[2]	pesticide	BAU / IPM
a[3]	fertilisation	BAU / durable
a[4]	cultivar	standard / premium (ST25)
a[5]	saisons	2 / 3 saisons

Observation : Box(9) → **Box(11)** (4 état + 6 action + 1 indice d'année).

2.2 Conséquence technique : la durée d'année devient dépendante des actions


Le cultivar (temps thermique de maturité différent) et le nombre de saisons changent la **date de récolte**, donc la **durée de l'année RL** (jusqu'à ce que tous les fermiers aient fini leurs saisons). Observé : de ~360 jours (tout-3-saisons) à **485–579 jours** quand des fermiers passent en 2 saisons / premium.

Le macro-pas Python a été rendu **robuste à l'overshoot** : si le grand saut groupé dépasse la frontière, l'estimation est rétractée (la récompense, elle, reste correcte car lue sur le *snapshot* de fin d'année).

À garder en tête : un « épisode de 10 ans RL » peut désormais couvrir **~13–16 années calendaires** selon les choix de saisons. L'interprétation de l'horizon et du discount γ se décale d'autant.


3. Résultats

3.1 Courbe d'apprentissage — elle MONTE



Contrairement à Box(4) (courbe descendante), la moyenne mobile **progresses de +17 %** (304k → 355k). Les leviers cultivar/saisons ont transformé un problème quasi-dégénéré en un **vrai problème d'optimisation** : l'agent apprend.


3.2 Comparaison aux baselines



politique	profit global	vs trained
fixed_high — AWD / IPM / durable / premium / 2 saisons	430 668	+34,6 %
trained (best = final)	319 949	référence
fixed_low — CF / BAU / BAU / standard / 3 saisons	255 457	−20,2 %
fixed_mid — CF / IPM / durable / standard / 3 saisons	234 025	−26,9 %
random	198 311	−38,0 %

La politique entraînée **bat random (+61 %), fixed_low (+25 %) et fixed_mid (+37 %) — mais reste −26 % sous fixed_high.**

3.3 Box(4) vs Box(6)



L'ajout des deux leviers **relève le plafond de profit** (meilleur baseline : 284k → **431k**) et **améliore la politique apprise** (285k → 320k). L'espace plus grand fait aussi chuter l'aléatoire (263k → 198k) : il y a beaucoup plus de mauvaises combinaisons possibles.

4. Interprétation

1. L'apprentissage devient efficace. C'est le premier run où l'agent progresse nettement et bat la plupart des baselines de 25 à 61 %. Donner des leviers à fort impact était la bonne piste.

2. Le cultivar premium est un game-changer. fixed_high atteint **431k** — presque le double de fixed_low — porté par le **riz premium (ST25)**, qui se vend bien plus cher. Cela **renverse l'optimum** identifié dans le rapport 1 (où le BAU intensif dominait) : désormais c'est la **montée en gamme** qui paie.

3. La politique sous-exploite ce filon (320k vs 431k). Elle a trouvé une bonne stratégie mixte mais **n'a pas convergé** vers « tous les fermiers en premium + 2 saisons » (le cultivar premium reste minoritaire dans ses choix). Elle laisse **~110k** sur la table.

4. Pourquoi ce plafonnement ? L'optimum (`fixed_high`) est, là encore, un **coin quasi-constant** presque indépendant de l'état. Avec la **récompense globale partagée** (crédit dilué $\div 10$) et 200 épisodes sur un espace 6D plus vaste, PPO se fixe sur un **optimum local** sans engager tous les fermiers sur le premium.

5. Conclusions

1. [OK] **Ajouter cultivar + saisons a un effet majeur et positif** : l'entraînement apprend vraiment (+17 % de courbe) et bat la plupart des baselines.
2. [obs] **Le riz premium (ST25) est la stratégie gagnante** (`fixed_high` $\approx$ 431k) ; elle redéfinit complètement l'optimum par rapport au BAU intensif du rapport 1.
3. [!] **La politique n'en capture que ~74 % (320k)** : elle reste sous le meilleur coin constant, freinée par l'attribution de crédit (récompense partagée) et la taille de l'espace.
4. [!] **Effet structurel** : le passage en 2 saisons / premium **allonge fortement la durée d'année** (jusqu'à ~580 jours), décalant l'interprétation de l'horizon.

Pistes pour combler l'écart (~110k) : récompense **par-agent** (meilleure attribution de crédit, l'optimum étant ~constant), **plus d'épisodes / exploration ciblée**, ou décroissance de l'entropie en fin d'entraînement.