

Rapport — Premier entraînement MARL sur Starfarm

Apprentissage par renforcement multi-agent (IPPO) pour la maximisation du revenu agricole global

1. Objectif

Starfarm est une simulation multi-agents (GAMA) d'un paysage rizicole : plusieurs **fermiers** gèrent chacun une exploitation de parcelles, en choisissant des **pratiques** (irrigation, pesticides, fertilisation). Un **marché** convertit les récoltes en revenu, avec un prix dynamique (la saturation du marché fait baisser les prix).

But de ce premier entraînement : apprendre, par fermier et par année, une combinaison de pratiques qui **maximise le revenu global = somme des profits annuels de tous les fermiers**, sur un horizon de 10 ans.

2. Méthodologie

2.1 Environnement et cadence

La simulation Starfarm est exposée à Python via **GAMA-server** et la bibliothèque `gama-pettingzoo` (interface PettingZoo ParallelEnv). L'agent-pont `PetzAgent` est **embarqué directement dans le monde Starfarm** (pas de co-modèle), de sorte que `client.step` fait avancer l'horloge de simulation normalement.

- **1 pas RL = 1 année simulée.** L'environnement Python (`StarfarmParallelEnv`) effectue un *macro-pas* : il applique les décisions de l'année, fait avancer la simulation jour par jour jusqu'à la fin de l'année agricole (`year_done`), puis relève la transition.
- **Optimisation des échanges** : au lieu d'avancer un jour à la fois (~730 allers-retours GAMA↔Python par an), un seul appel `nb_step` groupé couvre l'essentiel de l'année, suivi d'une courte finition. La durée d'une année étant **indépendante des actions** (la maturité dépend uniquement du temps thermique = température), elle est mémorisée et réutilisée : ~10 allers-retours/an après calibration.

2.2 Espace d'action — `Box(4)` continu (∈ [0,1])

Chaque dimension pilote une **fonction de changement de régime** du modèle :

dim	levier	décodage
<code>a[0]</code>	irrigation	< 0.5 → CF (flooding continu) ; ≥ 0.5 → AWD (assèchement alterné)
<code>a[1]</code>	quantité d'irrigation	profondeur d'inondation CF [30–70 mm] / seuil de sécheresse AWD [–50...–250 mm]
<code>a[2]</code>	pesticide	≥ 0.5 → IPM (lutte intégrée, moins d'intrants) ; sinon BAU
<code>a[3]</code>	fertilisation	≥ 0.5 → durable (dose réduite) ; sinon BAU

Les pesticides et la fertilisation sont donc des **régimes binaires** (conventionnel BAU vs durable/IPM), avec des cartes de seuils par saison fidèles au modèle.

2.3 Observation — Box(9)

Par fermier, en fin d'année : **4 variables d'état** + **4 dernières actions** + **1 indice d'année normalisé**.

#	variable d'état	rôle
1	profit de l'an dernier	résultat économique
2	fertilisant moyen appliqué	effet de l'action
3	santé du sol moyenne	état persistant
4	rendement final moyen (t/ha)	résultat agronomique

(Cinq variables initialement envisagées — revenu, coûts, usage d'eau, charge ravageurs, niveau d'eau — ont été retirées : au moment du relevé (post-récolte) elles sont écrasées, instantanées, ou valent ~0, donc sans signal.)
Normalisation (moyenne/écart-type courants) côté Python.

2.4 Récompense

Récompense globale partagée : chaque fermier reçoit $r = \Sigma$ profits annuels de tous les fermiers de l'année écoulée. Elle est alignée sur l'objectif (le bien-être collectif) et stabilise l'apprentissage coopératif. (Un mode « par fermier » est aussi disponible.)

2.5 Algorithmme — IPPO

Independent PPO à poids partagés : un **seul** réseau acteur-critique (politique **gaussienne diagonale** pour l'action continue) est partagé par les 10 fermiers ; leurs transitions sont mises en commun pour la mise à jour PPO. Avantages estimés par GAE, objectif clippé, bonus d'entropie.


2.6 Protocole d'entraînement

hyperparamètre	valeur	hyperparamètre	valeur
épisodes	200	clip ϵ	0.2
horizon	10 ans	k epochs	4
γ (discount)	0.95	minibatch	64
GAE λ	0.95	couche cachée	128
learning rate	3e-4 $\rightarrow$ 0 (annealing linéaire)	coef. entropie	0.01
reward scale	1e-6	coef. valeur	0.5

Deux garde-fous ont été ajoutés : **sauvegarde du meilleur modèle** (best_*.pth, par moyenne mobile) séparément du dernier, et **annealing du learning rate**.


3. Résultats

3.1 Courbe d'apprentissage



Le retour DÉCLINE au fil de l'entraînement : il part de ~282k (épisode 0, qui est aussi le **maximum**) et descend régulièrement vers ~271k. L'algorithme ne s'améliore donc pas — au contraire, il **dérive** en s'éloignant d'une bonne politique initiale. C'est exactement pourquoi le **mécanisme de meilleur-checkpoint** est crucial : il a conservé la bonne politique précoce (que le modèle final, dégradé, n'aurait pas fournie).

3.2 Comparaison aux baselines



Évaluation en politique **déterministe (greedy)**, profit global moyen sur 10 ans :

politique

profit global


écart vs

fixed_low

trained (best)	284 806	+0,1 %
fixed_low (CF / BAU / BAU)	284 404	référence
trained (final)	275 132	-3,3 %
fixed_mid (CF / IPM / durable)	265 727	-6,6 %
random	262 850	-7,6 %
fixed_high (AWD / IPM / durable)	262 374	-7,7 %

Lecture : - Le meilleur modèle égale le meilleur baseline constant (fixed_low) et bat tout le reste de +7 à +8 % (hasard, régimes durable/IPM, AWD). - Dans ce modèle, **l'agriculture intensive conventionnelle (BAU) maximise le profit** : réduire les intrants (IPM, fertilisation durable, AWD) fait perdre plus en rendement que ça n'économise en coûts. - La politique entraînée a donc **correctement convergé** vers ce régime BAU intensif.

3.3 Dynamique intra-épisode



À l'intérieur d'un épisode, le **profit annuel décroît** (~35k la 1^{ère} année → ~22k la 10^{ème}). Cela reflète une **dynamique du modèle** (vraisemblablement dégradation progressive de la santé du sol / pression cumulée), indépendante de la qualité de l'apprentissage. C'est une piste agronomique intéressante : la rentabilité n'est pas soutenable telle quelle sur 10 ans.

4. Discussion

Pourquoi l'apprentissage dérive-t-il ? L'optimum de ce problème est une politique **quasi-constante** (« tout le monde en BAU intensif »), presque indépendante de l'état. Il n'y a donc **quasiment rien à apprendre** au-delà d'une constante : la politique initiale est déjà proche de l'optimum, et l'exploration PPO ne fait que s'en éloigner (vers les régimes durable/AWD, moins rentables). Le bonus d'entropie entretient cette exploration improductive.

Déterminisme. L'environnement est **déterministe** (météo chargée d'un fichier fixe, durée d'année indépendante des actions) : pour une politique donnée, le résultat est strictement reproductible (écart-type = 0). Il n'y a donc

aucune pression de généralisation, ce qui renforce le caractère dégénéré du problème pour le RL.

Attribution de crédit. La récompense globale partagée dilue la contribution individuelle de chaque fermier (1/10), ce qui brouille le signal d'apprentissage — un facteur classique de difficulté en MARL coopératif, qui contribue aussi à la dérive.

5. Conclusions

1. [OK] **Le pipeline MARL fonctionne de bout en bout** : action continue Box (4) pilotant les pratiques, observation Box (9), IPPO gaussien, macro-pas optimisé, évaluation contre baselines.
2. [OK] **Le meilleur modèle est quasi-optimal** : il atteint le meilleur régime constant (BAU intensif) et bat hasard/durable/AWD de **+7 à +8 %**.
3. [!] **L'entraînement ne « progresse » pas** : il dérive ; seul le meilleur-checkpoint sauve le résultat. **Toujours déployer --best, jamais le modèle final.**
4. [obs] **Résultat métier** : dans ce modèle, **les intrants conventionnels (BAU) maximisent le profit** ; et la **rentabilité décroît sur l'horizon** (signal de non-durabilité).