

Bilan global : pilotage par IA multi-agents de la simulation Starfarm

Projet Starfarm, apprentissage par renforcement multi-agents (MARL). Juillet 2026.

Ce document est le bilan de l'ensemble du travail RL mené sur la simulation rizicole Starfarm : ce qui a été construit, ce que les expériences montrent, ce que l'IA a révélé du modèle lui-même, et ce qui reste à faire. Il est organisé par questions ; le cheminement chronologique (choix, impasses, corrections) est résumé en annexe A. Chaque section renvoie aux rapports et fichiers Excel détaillés (annexe B). Les aspects purement algorithmiques sont couverts par la note technique en anglais [note_methodo_rl.pdf](#), destinée aux experts RL.

Résumé exécutif

À lire avant les chiffres. Les sections 2 à 4 rapportent des mesures antérieures à la recalibration du modèle et à l'arrivée de la province Dong Thap. Les valeurs à jour sont en **section 8** et **annexe C**, et ne sont pas comparables à celles-ci : la recalibration a modifié l'économie du modèle (la stratégie constante MaxProfit passe de 373 k à 47 k de profit à 10 fermes, MinPollution change de signe). Les conclusions **2** et **3** ci-dessous sont corrigées en section 8.

Six politiques d'IA ont été entraînées sur la carte simplifiée (10 fermes, 25 ans simulés), avec un seul facteur variable : l'objectif de récompense (profit ; pollution ; ou un compromis profit moins lambda fois pollution, pour quatre valeurs de lambda). Elles ont ensuite été évaluées sans réentraînement sur la carte réelle (748 fermes), en décision déterministe (greedy) et échantillonnée (stochastique), et confrontées à deux stratégies constantes sans IA. Quatre conclusions principales :


L'IA apporte une valeur mesurable, et cette valeur est temporelle plus qu'agronomique. La politique Profit bat la meilleure stratégie constante (tout le monde en premium, en continu) de +30 % à 10 fermes et +27 % à 748 fermes, à pratiques agricoles identiques : elle gagne en modulant l'adoption du premium au rythme du marché, pas en cultivant mieux.

Le compromis profit / pollution est pilotable par un seul paramètre. Le poids lambda trace une frontière exploitable : lambda = 100k conserve 77 % du profit en réduisant la pollution de 22 à 44 % selon l'échelle ; lambda = 400k réduit la pollution de 57 % en conservant 25 % du profit. A l'inverse, l'objectif "pollution seule" échoue : il est dominé par les politiques équilibrées dans toutes les conditions testées. **Conclusion revue en section 8.3** : le balayage n'ayant reçu qu'une graine et un budget fixe par valeur de lambda, il ne permet pas d'établir la forme de cette frontière.

Le passage à l'échelle fonctionne. L'architecture (acteur partagé sans identifiant d'agent) transfère de 10 à 748 fermes sans réentraînement, et la hiérarchie des politiques y devient plus propre qu'à petite échelle. En contrepartie, l'écart entre décision déterministe et échantillonnée, négligeable à 10 fermes, devient un facteur de premier ordre à 748 (jusqu'à -49 % de profit pour la politique Profit). **À préciser depuis, section 8.2** : c'est vrai pour l'échelle (97 % du profit par ferme conservé, sur deux provinces) mais faux pour la province - cinq politiques sur six perdent leur avantage en changeant de carte, trois passent sous la stratégie sans IA.

L'IA est aussi un outil d'audit du modèle. Trois faiblesses de modélisation ont été mises en évidence par l'entraînement : la pollution ne provient que des pesticides (l'irrigation AWD et la fertilisation durable n'y contribuent pas) ; l'observation de rendement est aveugle en calendrier 3 saisons ; et le choix "3 saisons" est rejeté par toutes les politiques, probablement en partie à cause de ces défauts.

Frontière profit / pollution — 4 conditions (haut-droite = idéal ; étoiles = stratégies constantes sans IA)



La figure de synthèse : chaque point est une politique entraînée, chaque étoile grise une stratégie constante sans IA. Haut-droite = idéal (profit haut, pollution basse). Les étoiles sont dominées dans tous les panneaux où elles figurent.

1. Le dispositif en bref

La simulation. Starfarm (GAMA) simule des exploitations rizicoles du delta du Mékong : parcelles, sols, ravageurs, salinité, pollution, marché du riz avec rétroaction des prix. Deux cartes : simplifiée (10 fermes, utilisée pour l'entraînement) et réelle (748 fermes, utilisée pour tester le transfert). Un épisode = 25 années de culture.

Depuis la recalibration, une seconde province est disponible et le dispositif compte donc quatre cartes : Dong Thap old (10 / 748 fermes) et Dong Thap (10 / 992). La distinction entre changement d'échelle et changement de province est le résultat central de la section 8.

Ce que l'IA décide. Chaque ferme, chaque année, choisit 6 leviers : régime d'irrigation (inondation continue CF ou alternance AWD) et son intensité ; régime de pesticides (conventionnel BAU ou lutte intégrée IPM) ; fertilisation (BAU ou durable) ; cultivar (standard OM5451 ou premium ST25, mieux payé mais dont le prix chute si trop de fermes le choisissent) ; et nombre de saisons de culture (2 ou 3).

Ce que l'IA observe. 18 grandeurs par ferme : état local (profit de l'année précédente, santé du sol, rendement, engrais appliqué, pollution et salinité de la cellule), descripteurs statiques de la ferme (nombre de parcelles, surface), signaux de marché globaux (part de riz premium dans le paysage, prix relatif du premium), position dans le tour de décision, et repères temporels (dont l'indice de l'année dans l'épisode).

Les décisions sont séquentielles. Chaque année, les fermes décident une par une dans un ordre aléatoire, en voyant la part de premium déjà engagée par celles qui ont décidé avant. C'est ce qui permet à une politique partagée par toutes les fermes de se différencier : sans cela, toutes prendraient la même décision et le marché premium s'effondrerait (problème classique de coordination type "El Farol").

L'algorithme. MAPPO : un acteur gaussien unique partagé par toutes les fermes (aucun identifiant d'agent en entrée, ce qui rend le transfert d'échelle possible) et un critique centralisé qui voit l'état global pendant l'entraînement

uniquement. Récompense annuelle densifiée par sous-étapes saisonnières, actualisation ajustée à la durée réelle des pas. Détails, hyperparamètres et justifications dans [note_methodo_r1.pdf](#).

Les six politiques comparées. Profit (récompense = profit par ferme) ; Pollution (récompense = moins la pollution) ; et quatre politiques équilibrées Bal-20k, Bal-100k, Bal-200k, Bal-400k (récompense = profit moins lambda fois pollution, lambda croissant). Entraînements de 600 à 800 épisodes selon les runs, même pipeline pour tous.

Ces budgets sont ceux des entraînements pré-recalibration décrits dans les sections 2 à 4. Les runs rejoués après recalibration (sections 8 et 9, annexe C) sont tous à 400 épisodes - c'est ce budget-là, uniforme et fixé d'avance, que la section 8.3 identifie comme insuffisant pour les valeurs élevées de lambda.

2. Question 1 : l'IA apporte-t-elle quelque chose ?

C'est la question préalable à toute la suite, et elle exige un point de comparaison extérieur : des stratégies **sans IA**. Deux stratégies constantes ont été évaluées, où chaque ferme applique le même paquet de pratiques chaque année, quoi qu'il arrive :

- **MaxProfit (sans IA)** : 100 % premium pour tout le monde, sur le paquet conventionnel vers lequel la politique Profit a elle-même convergé (CF à lame d'eau minimale, BAU, 2 saisons). C'est la lecture littérale de "tout le monde à fond sur ce qui rapporte".
- **MinPollution (sans IA)** : 100 % des pratiques vertes en continu (AWD doux, IPM, fertilisation durable, cultivar standard, 2 saisons).

Stratégie	Profit 10 fermes	Pollution	Profit 748 fermes	Pollution
Profit (IA)	484,7 k	0,0357	35,22 M	0,0420
MaxProfit (sans IA)	373,2 k	0,0365	27,69 M	0,0480
Bal-100k (IA)	372,8 k	0,0200	27,30 M	0,0326
MinPollution (sans IA)	18,1 k	0,0350	1,19 M	0,0460

Mesures pré-calibration. Valeurs à jour en annexe C, non comparables à celles-ci.

Premier résultat : +30 % de profit à 10 fermes, +27 % à 748, par le seul timing. La stratégie MaxProfit n'échoue pas agronomiquement : ses sols restent sains (0,99) et ses rendements normaux (5,0 t/ha). Elle échoue économiquement, parce que 100 % de premium en permanence sature le marché et écrase le prix. La politique Profit adopte les mêmes pratiques agricoles, mais module le taux de premium (86 % en moyenne, pas 100 %) : elle sort du premium quand le prix casse et y revient ensuite. Toute sa valeur ajoutée est là.

Post-calibration, l'écart est bien plus large que ces +30 % : Profit atteint 46,2 k€/ferme contre 4,7 pour MaxProfit à 10 fermes, soit un facteur ~10 (annexe C). Le résultat est donc renforcé, mais le raisonnement ci-dessus - « MaxProfit n'échoue pas agronomiquement, elle échoue économiquement » - s'appuie sur des chiffres qui ne sont plus ceux du modèle actuel et resterait à re-vérifier sur les données à jour.

Deuxième résultat, plus contre-intuitif : cocher toutes les pratiques vertes ne dépollue presque pas.

MinPollution ne réduit la pollution que de 4 % par rapport à MaxProfit (0,0365 vers 0,0350 à 10 fermes ; 0,0480 vers 0,0460 à 748), en sacrifiant 95 % du profit. Pendant ce temps, Bal-100k atteint le **même profit que MaxProfit avec 32 % de pollution en moins** à 748 fermes, et Bal-400k fait 7,4 fois le profit de MinPollution avec 2,5 fois moins de pollution. Les deux stratégies constantes sont dominées au sens de Pareto, aux deux échelles.


L'interprétation tient en une phrase : **dans ce modèle, dépolluer n'est pas une question de pratiques mais de déclenchement.** La pollution vient des pulvérisations ; ce qui compte est de pulvériser peu quand la pression ravageur le permet, ce que seule une politique qui lit l'état du système sait faire.

2.1 La preuve micro : les fermes suivent le marché

L'évaluation ferme par ferme montre le mécanisme à l'oeuvre au niveau individuel. Sur un épisode de la politique Profit, on observe des cycles nets : les premières années, toutes les fermes sont en premium ; le prix se dégrade, les résultats s'écroulent, et la majorité bascule en standard ; le prix du premium se reconstitue, et le paysage rebasculé en premium. Ces vagues d'adoption et de retrait, ferme par ferme, sont la signature visible de la coordination temporelle qui explique l'écart avec la stratégie constante.

3. Question 2 : peut-on piloter le compromis profit / pollution ?

Une fois établi que l'IA maximise correctement le profit, la question opérationnelle devient : peut-on lui faire viser autre chose, et avec quel contrôle ? Le levier testé est le poids lambda dans la récompense "profit moins lambda fois pollution".



Politique	Profit (10 fermes)	Pollution	Premium	AWD	IPM	Durable
Profit	484,7 k	0,0357	86 %	0 %	4 %	0 %
Bal-20k	479,5 k (99 %)	0,0351	82 %	12 %	4 %	4 %
Bal-100k	372,8 k (77 %)	0,0200 (-44 %)	32 %	37 %	30 %	30 %
Bal-200k	319,9 k (66 %)	0,0312	20 %	19 %	50 %	34 %
Bal-400k	63,4 k (13 %)	0,0268	2 %	0 %	91 %	48 %
Pollution	265,9 k (55 %)	0,0332	14 %	15 %	44 %	43 %

Mesures pré-calibration. Valeurs à jour en annexe C, non comparables à celles-ci.

Le curseur lambda fonctionne, avec un seuil. En dessous d'environ 58 000 (valeur estimée par calcul sur les ordres de grandeur des deux termes), le terme de pollution est négligeable et la politique se comporte comme Profit (c'est le cas de Bal-20k). Au-delà, le compromis s'installe. A 10 fermes, Bal-100k est le point remarquable : pour -23 % de profit,

-44 % de pollution, via un mix équilibré (environ un tiers de premium, d'AWD, d'IPM et de durable). Il domine même les politiques plus contraintes (200k, 400k) sur les deux axes à la fois à cette échelle.

L'échec instructif : la politique "pollution seule". Entraînée uniquement à minimiser la pollution, elle devrait être la meilleure sur cet axe. Elle ne l'est nulle part. Son premier entraînement avait convergé vers un optimum dégénéré (IPM seul, quasi aucune autre pratique) ; réentraînée avec un taux d'apprentissage réduit, elle adopte un mix plausible mais reste battue par Bal-100k sur son propre objectif (0,0332 contre 0,0200), et son transfert à 748 fermes est mauvais (0,0465, pire que la politique Profit). Hypothèses, détaillées dans [rapport_complet.pdf](#) :


1. **Signal trop plat** : la pollution varie peu et lentement entre actions ; le gradient d'apprentissage est faible et l'exploration s'effondre. Le terme de profit du Balanced agit comme un guide d'exploration (reward shaping) qui découvre au passage les régimes peu polluants.
2. **Attribution du mérite difficile** : la pollution d'une ferme dépend de ses pulvérisations passées et de la diffusion depuis les voisines ; le lien action vers récompense est retardé et brouillé.
3. **Externalité collective** : réduire sa pollution profite d'abord aux voisins (diffusion), ce qui affaiblit une récompense individuelle.
4. **Piège de la boucle ravageur** : sans incitation au maintien d'un agrosystème sain, le système dérive vers un régime haute pression / haute pulvérisation. Le profit, lui, force à garder le système sain, donc peu polluant : c'est pourquoi la politique pollution-seule fait plus d'IPM mais plus de pollution.

Recommandation opérationnelle : ne jamais utiliser l'objectif pollution seul ; travailler sur la famille Balanced, avec lambda proche de 100k pour un scénario "agriculture raisonnée" et 400k pour un scénario "priorité environnement".

4. Question 3 : est-ce que ça passe à l'échelle ?

Les six politiques, entraînées sur 10 fermes, ont été rejouées telles quelles sur la carte réelle : 748 fermes, grille spatiale 4 fois plus fine, sans un seul épisode de réentraînement. C'est un test exigeant : la politique n'a jamais vu ni cette carte, ni cette densité de voisinage, ni cette taille de marché.

Trois objectifs de récompense — profit vs pollution (politique per-fermier, éval greedy)



Politique

Profit (748, greedy)

Pollution

Lecture

Profit	35,22 M	0,0420	référence
Bal-20k	30,11 M (85 %)	0,0471	dominée : lambda trop faible ne fait que dégrader
Bal-100k	27,30 M (77 %)	0,0326 (-22 %)	scénario "raisonné"
Bal-200k	17,89 M (51 %)	0,0281 (-33 %)	intermédiaire
Bal-400k	8,79 M (25 %)	0,0181 (-57 %)	scénario "environnement"
Pollution	15,98 M (45 %)	0,0465	dominée partout

Mesures pré-calibration. Valeurs à jour en annexe C, non comparables à celles-ci.

Le transfert fonctionne, et la grande échelle assainit même la lecture. A 748 fermes, la frontière devient propre et monotone : Bal-100k, 200k et 400k échangent régulièrement du profit contre de la pollution. La dominance totale de Bal-100k observée à 10 fermes ne se reproduit pas : elle tenait à l'environnement d'évaluation réduit, pas aux politiques. Fait notable, les politiques adaptent leur mix à la carte réelle (Bal-100k y passe à 79 % d'AWD et 70 % de durable, bien plus qu'à 10 fermes) : étant conditionnées à l'état, elles modulent leurs pratiques selon les fermes réelles, ce qui est exactement le comportement recherché.

La surprise : greedy et stochastique divergent fortement à grande échelle. En décision déterministe (greedy, l'action est la moyenne de la distribution), les chiffres sont ceux du tableau. En décision échantillonnée (stochastique), à 10 fermes rien ne change (écarts de 2 à 3 %) ; à 748 fermes, tout change :

- La politique Profit s'effondre de 35,2 M à 18,1 M (-49 %) : le bruit d'échantillonnage, multiplié par 748 fermes, casse la coordination premium collective.
- A l'inverse, les politiques très contraintes remontent : Bal-400k passe de 8,8 M à 14,4 M (+64 %), en devenant même légèrement plus verte. L'échantillonnage les sort d'un mode déterministe médiocre (effet de diversification type jeu de minorité).

Conséquence pratique : en déploiement, on joue la politique greedy, et les chiffres greedy sont la performance attendue. Mais l'écart greedy / stochastique doit devenir un indicateur de suivi standard : il mesure la fragilité de la coordination apprise, et il ne se voit qu'à l'échelle réelle.

5. Ce que l'IA a révélé du modèle Starfarm

Un agent qui optimise sans relâche finit par exploiter ou exposer les recoins du modèle. Trois découvertes de ce type, qui sont des retours directs pour l'équipe de modélisation.

5.1 La pollution ne vient que des pesticides. Dans le code actuel, seule la pulvérisation ajoute de la pollution (qui décroît puis diffuse vers les cellules voisines) ; ni l'irrigation (pas de méthane pour CF) ni la fertilisation (pas de ruissellement azoté) n'y contribuent. Conséquences : l'adoption d'AWD ou de fertilisation durable par les politiques "vertes" n'agit sur la pollution qu'indirectement, via la maîtrise de la pression ravageur ; et le résultat "MinPollution ne dépollue que de 4 %" doit se lire dans ce cadre. Si une version future du modèle fait contribuer l'eau et l'azote à la pollution, les conclusions de la section 3 devront être re-mesurées (la pipeline est prête pour cela).

5.2 L'observation de rendement est aveugle en calendrier 3 saisons. Découvert en construisant la stratégie sans-IA "intensive" : en 3 saisons, l'observation de rendement lit 0 en permanence, alors que les récoltes ont bien lieu (le profit est là). Cause mécanique : le rendement de parcelle est remis à zéro à chaque semis, et l'instant de décision annuel tombe après un semis en calendrier 3 saisons, avant que la récolte ne l'ait renseigné. C'est un vrai défaut d'instrumentation : une politique qui choisirait 3 saisons perdrait une observation sur 18.

5.3 Aucune politique ne choisit jamais 3 saisons, et c'est peut-être lié. Sur les six politiques entraînées, le taux de choix "3 saisons" est exactement 0 %. Deux mécanismes mesurés peuvent l'expliquer : la dégradation du sol triple (0,015 par an au lieu de 0,005, la jachère disparaissant) et l'observation de rendement devient muette (5.2). Il reste à

départager la part du signal agronomique réel et la part de l'artefact d'observation ; d'ici là, le rejet unanime des 3 saisons par l'IA ne doit pas être interprété comme une conclusion agronomique.

Au-delà de ces trois points, l'expérience El Farol du premium (section 2) est aussi une validation du modèle : la rétroaction prix-adoption du marché premium crée bien le problème de coordination qu'elle visait à représenter, suffisamment pour qu'une IA en tire un avantage de +27 à +30 %.

6. Limites de l'étude

- **Peu d'épisodes d'évaluation en réel** : un épisode par condition à 748 fermes (trois à 10 fermes en stochastique). Les écarts massifs (baselines, effondrement stochastique de Profit) sont robustes à ce bruit ; les écarts fins entre politiques voisines demanderaient des répétitions.
- **Entraînement uniquement à 10 fermes**. Le transfert à 748 est un résultat, mais rien ne dit qu'un entraînement (ou un affinage) directement à 748 fermes ne ferait pas mieux, notamment pour restaurer la coordination premium sous échantillonnage. Cependant les temps de calcul rendent l'entraînement irréalisable en pratique.
- **Choix de checkpoint hétérogène** : la politique Profit est évaluée sur son meilleur checkpoint (sélectionné par profit greedy), les autres sur leur checkpoint final, la sélection "best" n'ayant pas de sens pour un objectif différent du profit.
- **Un seul seed d'entraînement par politique**. La non-monotonie résiduelle de la frontière à 10 fermes (Bal-200k et 400k dominés localement) ressemble à des optima locaux ; du multi-seed trancherait. **Mesuré depuis** : rejouer $\lambda = 200k$ avec une autre graine, tout le reste identique, multiplie le résultat par **3,7** - et le run d'origine n'avait pas convergé, il avait été arrêté (section 8.3). Cette limite s'est donc révélée plus lourde que supposée ici.
- **Les mesures proviennent de deux générations du modèle**. Sections 2 à 4 avant la recalibration, section 8 et annexe C après. Les valeurs absolues ne sont pas comparables entre les deux : la recalibration a modifié l'économie du modèle au point de faire changer de signe la stratégie constante MinPollution. Chaque section est cohérente avec sa propre génération de mesures ; aucune conclusion ne doit être tirée d'une comparaison croisée.
- **Bruit d'exploration indépendant de l'état** : l'écart-type de la politique (`log_std global`) module l'écart greedy / stochastique ; une paramétrisation dépendante de l'état changerait sans doute la section 4.

7. Recommandations et suite

Pour l'exploitation des résultats : 1. Retenir la famille Balanced comme livrable : λ proche de 100k (77 % du profit, -22 à -44 % de pollution) en scénario raisonné, 400k en scénario environnement ; affiner éventuellement λ par balayage local (60k à 140k). 2. Déployer en greedy, et suivre l'écart greedy / stochastique comme indicateur de fragilité de la coordination. 3. Ecarter définitivement l'objectif pollution-seul.

Pour le modèle Starfarm : 4. Faire contribuer l'irrigation et la fertilisation à la pollution (ou documenter que la variable représente les seuls pesticides), puis re-mesurer la frontière. 5. Corriger l'observation de rendement en calendrier 3 saisons (lire la dernière récolte plutôt que la valeur courante remise à zéro au semis).

Pour la suite du travail RL : 6. Répéter les évaluations réelles (5 à 10 épisodes) pour quantifier la variance. 7. Tester un affinage (fine-tuning) à 748 fermes, en particulier pour la politique Profit sous échantillonnage. 8. Multi-seed sur les politiques équilibrées pour confirmer la forme de la frontière.

8. Mise à jour post-calibration (août 2026)

Après la recalibration du modèle et l'arrivée d'une seconde province (Dong Thap, ajoutée par Patrick Taillandier), les six politiques ont été réévaluées sur **quatre cartes** au lieu de deux : deux provinces x deux échelles (10 / 748 fermes pour Dong Thap old, 10 / 992 pour Dong Thap). Deux entraînements de contrôle ont ensuite levé deux ambiguïtés. Trois conclusions du bilan ci-dessus sont **confirmées**, deux sont **corrigées**.

8.1 Confirmé : le passage à l'échelle fonctionne

L'acteur partagé conserve **97 %** du profit par ferme de 10 à 748 fermes, et **97 %** de 10 à 992 sur la nouvelle province. La propriété tient donc sur deux cartes indépendantes, ce que la section 4 ne pouvait pas établir.


8.2 Corrigé : le changement de PROVINCE ne transfère pas

La section 4 conclut « le transfert fonctionne » sur la base d'un seul changement d'échelle, à province constante. En séparant les deux axes, ils se comportent à l'opposé.

Écart à la meilleure stratégie constante **de la même carte** (k€/ferme ; > 0 = bat le sans-IA) :

politique	old simple	old complet	new simple	new complet
Profit	+41,4	+33,9	+36,1	+20,0
Bal-100k	+18,9	+2,4	+14,5	+1,3
Bal-20k	+26,9	+16,4	-1,7	+2,2
Bal-400k	+8,8	-7,0	-11,1	-4,6
Bal-200k	-1,5	-17,3	+3,6	-13,3
Pollution	-10,2	-35,3	-22,0	-35,0

Transfert des 6 politiques MAPPO — entraînées sur Dong Thap old simple (10 fermes)



L'équivalent post-calibration de la figure du résumé exécutif. Panneau 1 : profit par ferme, seule mesure comparable entre cartes. Panneau 3 : écart à la baseline sans IA de chaque carte - la ligne rouge est le niveau de la stratégie constante, tout ce qui passe en dessous est battu par une conduite qui ignore l'état.

Cinq politiques sur six perdent leur avantage en changeant de province, trois passent sous la baseline. Seule Profit reste solidement positive partout, en perdant tout de même ~40 %.

Ce n'est pas une question de difficulté de carte : réentraînée directement sur Dong Thap, la récompense lambda=20k atteint **+45,2 k€/ferme** (contre -1,7 en transfert) et dépasse même Profit. Son retour d'entraînement y démarre à +204 567 contre -80 053 sur la carte d'origine - la nouvelle province est **plus favorable**, et le transfert y échoue quand

même.

Mais le gain du réentraînement ne survit pas au passage à l'échelle. Profit réentraînée sur Dong Thap obtient +45,9 k€/ferme sur la carte simplifiée contre +36,1 en transfert, soit +9,9 - et **+19,5 contre +20,0 sur la carte complète**, c'est-à-dire rien. À 992 fermes les trois meilleures politiques tiennent dans 1,5 k€/ferme, moins que ce qu'un seul épisode permet de distinguer.

Plus frappant, la robustesse à l'échelle s'inverse selon l'origine de la politique :

politique	profit par ferme conservé, 10 fermes -> carte complète
Profit transférée (2 provinces)	97 %, 97 %
Bal-20k @DT	75 %
Profit @DT	70 %
Bal-200k v2	38 %


Les politiques transférées passent mieux à l'échelle que celles entraînées sur place, systématiquement sur quatre mesures. L'explication la plus économique serait un surajustement à la configuration des dix fermes d'entraînement (notamment aux dynamiques de saturation du marché premium, très différentes à 10 et à 992) dont une politique venue d'ailleurs est par construction préservée. **Hypothèse non testée.**

Conséquence pratique : **réentraîner sur la carte cible fait gagner beaucoup sur petite carte et rien de mesurable en déploiement réel.** Et surtout : un gain mesuré sur carte simplifiée ne préjuge pas du gain à l'échelle.

8.3 Corrigé : le sweep lambda n'est pas concluant en l'état

La section 3 (« le compromis est pilotable par un seul paramètre ») s'appuie sur un sweep où chaque valeur de lambda a reçu **une seule graine et un budget fixe de 400 épisodes**. Or :

- **La graine déplace le résultat d'un facteur ~4.** lambda=200k rejoué avec la graine 1 : 128 655 au lieu de 34 967 en évaluation greedy d'entraînement, et 12,9 k€/ferme au lieu de 3,2 en évaluation.
- **Les lambda élevés convergent beaucoup plus lentement.** lambda=20k plafonne dès l'épisode 74 ; lambda=200k montait encore à l'épisode 374 - le budget tronque l'entraînement au lieu de le terminer.



Panneau du haut : profit global en évaluation greedy tous les 25 épisodes. Traits pleins = Dong Thap old, comparables entre eux ; pointillés = Dong Thap, dont l'économie de base diffère et qui ne se comparent donc pas aux précédents. Les deux courbes lambda=200k (graine 0 et graine 1) illustrent directement le propos : même configuration, trajectoires sans rapport. En dessous, le retour d'entraînement de chaque run, chacun à son échelle puisque les récompenses diffèrent.

Les résultats du sweep confondent donc trois causes indissociables a posteriori : mauvaise valeur de lambda, budget insuffisant, tirage défavorable. **La forme de la frontière profit / pollution reste à établir** ; il faudrait 3 à 5 graines par valeur et un critère d'arrêt sur convergence. La recommandation 8 de la section 7 devient un prérequis, pas une option.

Nuance : même avec la bonne graine, lambda=200k reste **sous la baseline sans IA** à l'échelle réelle (−6,2 k€/ferme). La graine change l'ampleur de l'échec, pas sa nature.

8.4 Confirmé et renforcé : l'axe pollution ne répond pas à son levier

La section 5.1 notait que seule la pulvérisation produit de la pollution. Les quatre cartes le confirment et vont plus loin : **forcer l'IPM à 100 % n'obtient la pollution la plus basse sur aucune des quatre cartes**, et la politique entraînée spécifiquement à la minimiser ne l'obtient jamais non plus. Sur les quatre conditions, c'est Bal-20k qui pollue le moins, avec seulement 13 à 36 % d'IPM.

Le sweep lambda optimisait donc contre une cible que les politiques ne pouvaient pas piloter - ce qui explique les runs dégénérés bien mieux qu'un « lambda mal choisi ». La recommandation 4 (faire contribuer eau et azote à la pollution) en devient prioritaire : sans elle, l'axe environnemental du livrable n'est pas actionnable.

8.5 Nouveau : la carte simplifiée surestime les performances

La stratégie constante sans IA **s'améliore** avec l'échelle (+4,7 -> +11,1 k€/ferme sur Dong Thap old ; -8,6 -> +6,6 sur Dong Thap) pendant que la plupart des politiques se dégradent. Sur 10 fermes, quatre politiques semblent battre le sans-IA ; sur la carte réelle, deux seulement gardent une marge nette.

La carte simplifiée reste un bon terrain **d'entraînement** (le calcul y est 25 à 50 fois moins cher) mais un mauvais terrain de **mesure**. Toute performance annoncée doit l'être sur la carte de déploiement.

8.6 Prérequis technique introduit

province et simple_spatial_data sont devenus des paramètres de l'expérience marl, pilotables depuis la section gama: des configs YAML, à l'entraînement comme à l'évaluation. La carte est relue dans la simulation au démarrage et le run échoue immédiatement si GAMA a ignoré un paramètre - sans quoi 400 épisodes peuvent tourner sur la mauvaise province sans que rien ne le signale.

Pour la reproductibilité : le renommage amont plot_shapefile-simple -> plot_shapefile_simple avait laissé Dong Thap old de côté, rendant la carte d'entraînement d'origine inchangeable. La province a été migrée (renommage des composants du shapefile + carte de vulnérabilité _simple).

Détail : rapport_transfert.pdf, rapport_update_seed_et_transfert.pdf, rapport_eval_controls.pdf.
Figures : fig_apprentissage_mappo3.png, eval_conditions_curves.png.

9. Ouverture : ce que ces résultats rendent possible, et ce qu'ils laissent ouvert

Cette section est délibérément prospective. Elle sépare ce qui est **acquis** de ce qui est **plausible mais non testé**, pour que la suite du travail ne reparte pas d'hypothèses prises pour des résultats.

9.1 Ce qui est acquis et directement réutilisable

- **Un acteur partagé transfère à l'échelle** : 97 % du profit par ferme conservé de 10 à 748 fermes, et de 10 à 992, sur deux provinces. C'est la brique la plus solide du travail.
- **Un pipeline paramétrable de bout en bout** : province et échelle se règlent depuis le YAML, à l'entraînement comme à l'évaluation, avec vérification que GAMA a bien pris les paramètres. Ajouter une province tierce ne demande aucune modification de code.
- **Un protocole d'évaluation qui ne se ment pas** : chaque carte porte ses propres stratégies constantes sans IA, seule référence qui rende les chiffres comparables entre cartes.
- **Un export ONNX** avec normalisation des observations intégrée au graphe, utilisable en inférence hors de PyTorch.

9.2 La question la plus intéressante laissée ouverte

Les politiques **transférées** passent mieux à l'échelle que celles **entraînées sur place** (97 % contre 70-75 %), systématiquement sur quatre mesures. Autrement dit : s'entraîner sur la carte cible à petite échelle produit une politique meilleure sur cette petite carte et moins robuste à l'échelle réelle.

L'explication la plus économique serait un surajustement à la configuration des dix fermes d'entraînement; notamment aux dynamiques de saturation du marché premium, très différentes à 10 et à 992, dont une politique venue d'ailleurs est par construction préservée. **Cette hypothèse n'est pas testée.**

L'expérience qui la trancherait est simple : entraîner la même récompense sur **30 puis 50 fermes** et mesurer la robustesse à l'échelle. Si elle remonte avec la taille du terrain d'entraînement, l'hypothèse tient et la conséquence pratique est nette - il existe une taille d'entraînement minimale en deçà de laquelle les gains mesurés sont illusoires. Le coût est modéré : les cartes intermédiaires n'existent pas encore mais se génèrent avec `Utils/1_Generate_Plot_Shapefile.gaml`.

9.3 Prérequis avant toute nouvelle conclusion sur lambda

Le balayage lambda, tel qu'il a été mené, ne permet pas de conclure (section 8.3). Pour le rendre exploitable :

1. **3 à 5 graines par valeur de lambda.** Une seule graine déplace le résultat d'un facteur ~ 4 .
2. **Un critère d'arrêt sur convergence** plutôt qu'un budget fixe : les lambda élevés convergent 4 fois plus lentement et 400 épisodes les tronquent.
3. **Une évaluation sur la carte de déploiement**, pas sur la carte simplifiée.

Sans ces trois points, toute frontière profit / pollution publiée restera contestable.

9.4 Le verrou de modélisation

L'objectif environnemental est **inexploitable en l'état**, et c'est désormais démontré plutôt que supposé : sur quatre cartes, deux provinces, deux échelles, en transfert comme en entraînement direct, la politique dédiée à la pollution ne l'obtient jamais la plus basse. Le signe le plus parlant est qu'entraînée sur place à 992 fermes, elle **abandonne complètement l'IPM** (0 %) - elle a correctement appris que le seul levier disponible ne fait pas baisser la mesure, la boucle pollution -> pression ravageur -> nouveaux épandages en annulant l'effet.

Tant que l'irrigation et la fertilisation ne contribueront pas à la pollution (recommandation 4), aucun objectif environnemental ne sera optimisable dans ce modèle. **C'est le prérequis n°1** : il ne s'agit pas d'améliorer l'apprentissage mais de rendre l'objectif atteignable.

9.5 Pistes plus exploratoires

- **Décision tour par tour (AEC).** Les fermiers décident déjà séquentiellement en ordre aléatoire, chacun voyant les engagements des précédents. L'API AEC de PettingZoo modélise exactement ça et rendrait le mécanisme explicite plutôt qu'émulé dans l'environnement parallèle. Une implémentation générique a été contribué à `gama-pettingzoo` pendant le stage ; la brancher sur Starfarm est un chantier distinct, pas une simple bascule.
- **Affinage à grande échelle.** Partir d'une politique entraînée à 10 fermes et l'affiner quelques dizaines d'épisodes à 748 : coût faible, et cela testerait si l'on peut cumuler la robustesse du transfert et la spécialisation du réentraînement.
- **Hétérogénéité des fermiers.** L'acteur est partagé et ne voit que l'état de sa ferme. Conditionner sur un profil (aversion au risque, accès au crédit) permettrait d'étudier l'adoption différenciée des pratiques, qui est une question agronomique en soi.
- **Écart greedy / stochastique comme indicateur de suivi.** Déjà recommandé en section 7 ; la campagne à quatre cartes n'a pas été rejouée en stochastique, faute de temps machine.

Annexe A : chronologie et leçons du cheminement

1. **Premiers pas (IPPO, décisions simultanées).** Un premier pipeline PPO indépendant par agent a validé la connexion GAMA-Python et le cycle d'entraînement, mais s'est heurté à deux murs : les écritures dans la simulation via l'endpoint d'expressions du serveur GAMA rejettent les affectations directes, ce qui a imposé de passer par des appels d'actions GAML dédiés ; et surtout, une politique partagée avec décisions simultanées rendait toutes les fermes identiques, faisant s'effondrer le marché premium (problème El Farol).
2. **Décisions séquentielles.** L'introduction d'un tour de décision annuel en ordre aléatoire, où chaque ferme observe la part de premium déjà engagée, a permis la différenciation sans identifiant d'agent : c'est la clé de voûte du dispositif actuel.
3. **Passage à MAPPO et récompense densifiée.** Critique centralisé (information globale à l'entraînement seulement), récompense saisonnière par sous-étapes, actualisation ajustée à la durée réelle des pas : la convergence est devenue nette et reproductible.
4. **Récompense par agent contre récompense globale.** Les deux modes convergent, le mode par-agent facilitant l'attribution du mérite ; un run global prolongé à 800 épisodes a servi de référence de stabilité (rapport dédié).

5. **Analyse par fermier.** L'export Excel par ferme et par année a montré les cycles premium (section 2.1) et permis de vérifier que les fermes rentables ne le sont pas par taille mais par timing.
6. **Test de scalabilité.** Premier passage sur la carte réelle : le transfert 10 vers 748 fonctionne, ce qui a ouvert toute la campagne d'évaluation à grande échelle.
7. **Objectifs multiples.** Ajout des modes de récompense pollution et équilibré (sans toucher à la structure du code : un entier de mode et un poids lambda côté GAML). Le premier entraînement pollution a convergé vers un optimum dégénéré, corrigé par un réentraînement à taux d'apprentissage réduit ; leçon : les objectifs à signal plat demandent des réglages plus prudents.
8. **Balayage lambda.** Trois entraînements supplémentaires (100k, 200k, 400k) ont tracé la frontière de la section 3.
9. **Evaluations stochastiques.** La comparaison greedy / échantillonné aux deux échelles a révélé la fragilité de la coordination à 748 fermes (section 4).
10. **Baselines sans IA.** Les deux stratégies constantes ont fermé la boucle en donnant aux résultats un point de comparaison extérieur (section 2), et ont révélé au passage le défaut d'observation du rendement en 3 saisons (section 5.2).

Incidents notables et corrections : une reprise d'entraînement mal configurée a écrasé un checkpoint (récupéré via sauvegarde, et un garde-fou de sauvegarde automatique a été ajouté au trainer) ; une erreur d'étiquette sur les premières figures Pareto ("haut-gauche = idéal" au lieu de haut-droite) a été corrigée ; une conclusion intermédiaire erronée ("pollution inélastique, plancher 0,0285", tirée de la seule politique pollution) a été invalidée par Bal-100k (0,0200) et retirée.

Suite : après la recalibration et l'arrivée de Dong Thap (août 2026)

11. **Déblocage de la carte d'entraînement.** La recalibration a renommé la convention des données simplifiées (`plot_shapefile-simple` -> `plot_shapefile_simple`) et rendu la carte de vulnérabilité conditionnelle elle aussi. Dong Thap a reçu les deux fichiers, mais `Dong Thap old` n'a pas été migrée : la carte sur laquelle les six politiques avaient été entraînées ne se chargeait plus. Symptôme trompeur - `envelope(plots_shapefile)` échoue *avant* `init`, donc aucun agent n'est créé et l'erreur ne se manifeste que côté Python, bien plus tard. Province migrée, puis tout le reste a pu suivre.
12. **Province et échelle en paramètres.** Ajout de `province` et `simple_spatial_data` comme paramètres de l'expérience `marl`, pilotables depuis le YAML à l'entraînement comme à l'évaluation, avec relecture des valeurs dans la simulation et échec immédiat si GAMA les ignore. Sans ce garde-fou, 400 épisodes peuvent tourner sur la mauvaise carte en silence.
13. **Campagne à quatre cartes.** Les 6 politiques rejouées sur deux provinces x deux échelles (10/748 et 10/992), chaque carte portant ses propres stratégies sans IA. C'est ce qui a séparé deux axes que la section 4 confondait : l'échelle transfère (97 %), la province non (5 politiques sur 6 y perdent leur avantage).
14. **Contrôle « graine ».** `lambda=200k` rejoué avec la graine 1, tout le reste identique : x3,7 en évaluation d'entraînement, x4 en évaluation. Le run d'origine n'avait pas échoué - il n'avait pas décollé dans le budget alloué. Conséquence : le balayage lambda, avec une graine et un budget fixe par valeur, ne permet pas de conclure (section 8.3).
15. **Contrôles « réentraînement sur place ».** `lambda=20k`, puis Profit, puis Pollution entraînés directement sur Dong Thap. Ils ont montré que l'échec du transfert n'était pas une difficulté de carte - la nouvelle province est même plus favorable - mais aussi, contre toute attente, que **le gain du réentraînement ne survit pas au passage à l'échelle** (+9,9 k€/ferme sur 10 fermes, -0,5 sur 992 pour Profit). Cette dernière mesure a invalidé une recommandation déjà écrite dans deux rapports, corrigée depuis.
16. **Fermeture de la question pollution.** Entraînée sur place à 992 fermes, la politique dédiée abandonne complètement l'IPM (0 %) : elle a correctement appris que le seul levier disponible ne fait pas baisser la mesure. Le diagnostic passe d'hypothèse à démonstration, sur quatre cartes, deux provinces, deux échelles, en transfert comme en direct.

Annexe B : index des livrables

Rapports (dossier `rl/report/`) : - `rapport_bilan.pdf` : ce document. - `note_methodo_rl.pdf` : note technique RL en anglais (architecture, hyperparamètres, choix de conception), pour relecture par des experts. - `rapport_pareto.pdf` : balayage lambda et frontière, avec sections stochastiques. - `rapport_complet.pdf` : synthèse des 4 conditions d'évaluation et hypothèses sur l'échec de l'objectif pollution. - `rapport_objectifs.pdf`, `rapport_scalabilite.pdf`, `rapport_eval_par_fermier.pdf`, `rapport_peragent_vs_global.pdf` : rapports d'étape thématiques.

Données (dossier `rl/`) : - `eval_objectives_comparison_greedy10 / _stoch10 / _bigmodel / _stoch748 / _greedy748_pollution .xlsx` : les 6 politiques par condition (feuilles "comparaison" et "detail" année x ferme). - `eval_baselines_comparison_simple / _full .xlsx` : stratégies constantes sans IA. - `eval_per_farmer_peragent.xlsx` : matrices année x ferme (rewards, cultivars, actions).

Code : voir `rl/README.md` (pipeline, configs, échelles, artefacts).

Annexe C : tableau complet des résultats post-calibration

Profit par ferme sur 25 ans (k€), et écart à la meilleure stratégie constante sans IA de la même carte - seule colonne comparable d'une carte à l'autre. Actions greedy ; 3 épisodes sur carte simplifiée, 1 seul sur carte complète.

Les 6 politiques du balayage lambda, entraînées sur Dong Thap old simplifiée

politique	old simple (10)	old complet (748)	new simple (10)	new complet (992)
Profit	46,2 -> +41,4	45,0 -> +33,9	27,5 -> +36,1	26,6 -> +20,0
Bal-20k	31,6 -> +26,9	27,6 -> +16,4	-10,2 -> -1,7	8,9 -> +2,2
Bal-100k	23,6 -> +18,9	13,6 -> +2,4	5,9 -> +14,5	7,9 -> +1,3
Bal-200k	3,2 -> -1,5	-6,1 -> -17,3	-5,0 -> +3,6	-6,7 -> -13,3
Bal-400k	13,5 -> +8,8	4,1 -> -7,0	-19,6 -> -11,1	2,0 -> -4,6
Pollution	-5,4 -> -10,2	-24,2 -> -35,3	-30,6 -> -22,0	-28,4 -> -35,0
MaxProfit (sans IA)	4,7	11,1	-8,6	6,6
MinPollution (sans IA)	-110,0	-105,4	-121,4	-115,1

Les 4 runs de contrôle

run	ce qui change	carte simplifiée	carte complète
Bal-200k v2	graine 0 -> 1	12,9 -> +8,2	4,9 -> -6,2
Bal-20k @DT	entraînée sur Dong Thap	36,6 -> +45,2	27,6 -> +21,0
Profit @DT	entraînée sur Dong Thap	37,4 -> +45,9	26,1 -> +19,5
Pollution @DT	entraînée sur Dong Thap	-13,1 -> -4,6	-27,2 -> -33,8

Pollution moyenne (bas = mieux)

Non comparable entre cartes : l'incrément vaut `pesticide_pollution_add x aire_parcelle / aire_cellule`, et ce rapport change avec la géométrie. À lire colonne par colonne.

politique	old simple	old complet	new simple	new complet
-----------	------------	-------------	------------	-------------

Bal-20k	0,0348	0,0055	0,0034	0,0058
Bal-100k	0,0451	0,0112	0,0077	0,0087
Profit	0,0614	0,0130	0,0066	0,0095
Pollution	0,0479	0,0131	0,0084	0,0110
<i>MinPollution (100 % IPM)</i>	<i>0,0681</i>	<i>0,0108</i>	<i>0,0064</i>	<i>0,0090</i>

Sur les quatre cartes, la pollution la plus basse est obtenue par **Bal-20k**, avec 13 à 36 % d'IPM - jamais par la politique qui vise cet objectif, ni par la stratégie qui force l'IPM à 100 %.

Robustesse à l'échelle (profit par ferme conservé, 10 fermes -> carte complète)

politique	profit par ferme conservé
Profit transférée, Dong Thap old	97 %
Profit transférée, Dong Thap	97 %
Bal-20k @DT (entraînée sur place)	75 %
Profit @DT (entraînée sur place)	70 %
Bal-200k v2 (entraînée sur place)	38 %

Livrables ajoutés après la recalibration

Rapports : rapport_transfert.pdf (6 politiques x 4 cartes), rapport_update_seed_et_transfert.pdf (effet de la graine, non-transférabilité), rapport_eval_controls.pdf (les 4 runs de contrôle), tutoriel_scripts.pdf (mode d'emploi).

Figures : fig_apprentissage_mappo3.png (10 courbes d'apprentissage), eval_conditions_curves.png (synthèse 4 cartes).

Données : eval_condition_<tag>.xlsx - 4 conditions canoniques (dtold_simple, dtold_full, dtnew_simple, dtnew_full) et 8 classeurs de contrôle ; eval_conditions_synthesis.xlsx (synthèse croisée).

Code : eval_conditions.py (évaluation multi-cartes), plot_conditions.py (synthèse), plot_learning.py (courbes d'apprentissage) ; train_mappo.py et l'expérience marl acceptent désormais province et simple_spatial_data en paramètres.