

Bilan global : pilotage par IA multi-agents de la simulation Starfarm

Projet Starfarm, apprentissage par renforcement multi-agents (MARL). Juillet 2026.

Ce document est le bilan de l'ensemble du travail RL mené sur la simulation rizicole Starfarm : ce qui a été construit, ce que les expériences montrent, ce que l'IA a révélé du modèle lui-même, et ce qui reste à faire. Il est organisé par questions ; le cheminement chronologique (choix, impasses, corrections) est résumé en annexe A. Chaque section renvoie aux rapports et fichiers Excel détaillés (annexe B). Les aspects purement algorithmiques sont couverts par la note technique en anglais [note_methodo_rl.pdf](#), destinée aux experts RL.

Résumé exécutif

Six politiques d'IA ont été entraînées sur la carte simplifiée (10 fermes, 25 ans simulés), avec un seul facteur variable : l'objectif de récompense (profit ; pollution ; ou un compromis profit moins λ fois pollution, pour quatre valeurs de λ). Elles ont ensuite été évaluées sans réentraînement sur la carte réelle (748 fermes), en décision déterministe (greedy) et échantillonnée (stochastique), et confrontées à deux stratégies constantes sans IA. Quatre conclusions principales :


L'IA apporte une valeur mesurable, et cette valeur est temporelle plus qu'agronomique. La politique Profit bat la meilleure stratégie constante (tout le monde en premium, en continu) de +30 % à 10 fermes et +27 % à 748 fermes, à pratiques agricoles identiques : elle gagne en modulant l'adoption du premium au rythme du marché, pas en cultivant mieux.

Le compromis profit / pollution est pilotable par un seul paramètre. Le poids λ trace une frontière exploitable : $\lambda = 100k$ conserve 77 % du profit en réduisant la pollution de 22 à 44 % selon l'échelle ; $\lambda = 400k$ réduit la pollution de 57 % en conservant 25 % du profit. A l'inverse, l'objectif "pollution seule" échoue : il est dominé par les politiques équilibrées dans toutes les conditions testées.

Le passage à l'échelle fonctionne. L'architecture (acteur partagé sans identifiant d'agent) transfère de 10 à 748 fermes sans réentraînement, et la hiérarchie des politiques y devient plus propre qu'à petite échelle. En contrepartie, l'écart entre décision déterministe et échantillonnée, négligeable à 10 fermes, devient un facteur de premier ordre à 748 (jusqu'à -49 % de profit pour la politique Profit).

L'IA est aussi un outil d'audit du modèle. Trois faiblesses de modélisation ont été mises en évidence par l'entraînement : la pollution ne provient que des pesticides (l'irrigation AWD et la fertilisation durable n'y contribuent pas) ; l'observation de rendement est aveugle en calendrier 3 saisons ; et le choix "3 saisons" est rejeté par toutes les politiques, probablement en partie à cause de ces défauts.

Frontière profit / pollution — 4 conditions (haut-droite = idéal ; étoiles = stratégies constantes sans IA)



La figure de synthèse : chaque point est une politique entraînée, chaque étoile grise une stratégie constante sans IA. Haut-droite = idéal (profit haut, pollution basse). Les étoiles sont dominées dans tous les panneaux où elles figurent.

1. Le dispositif en bref

La simulation. Starfarm (GAMA) simule des exploitations rizicoles du delta du Mékong : parcelles, sols, ravageurs, salinité, pollution, marché du riz avec rétroaction des prix. Deux cartes : simplifiée (10 fermes, utilisée pour l'entraînement) et réelle (748 fermes, utilisée pour tester le transfert). Un épisode = 25 années de culture.

Ce que l'IA décide. Chaque ferme, chaque année, choisit 6 leviers : régime d'irrigation (inondation continue CF ou alternance AWD) et son intensité ; régime de pesticides (conventionnel BAU ou lutte intégrée IPM) ; fertilisation (BAU ou durable) ; cultivar (standard OM5451 ou premium ST25, mieux payé mais dont le prix chute si trop de fermes le choisissent) ; et nombre de saisons de culture (2 ou 3).

Ce que l'IA observe. 18 grandeurs par ferme : état local (profit de l'année précédente, santé du sol, rendement, engrais appliqué, pollution et salinité de la cellule), descripteurs statiques de la ferme (nombre de parcelles, surface), signaux de marché globaux (part de riz premium dans le paysage, prix relatif du premium), position dans le tour de décision, et repères temporels (dont l'indice de l'année dans l'épisode).

Les décisions sont séquentielles. Chaque année, les fermes décident une par une dans un ordre aléatoire, en voyant la part de premium déjà engagée par celles qui ont décidé avant. C'est ce qui permet à une politique partagée par toutes les fermes de se différencier : sans cela, toutes prendraient la même décision et le marché premium s'effondrerait (problème classique de coordination type "El Farol").

L'algorithme. MAPPO : un acteur gaussien unique partagé par toutes les fermes (aucun identifiant d'agent en entrée, ce qui rend le transfert d'échelle possible) et un critique centralisé qui voit l'état global pendant l'entraînement uniquement. Récompense annuelle densifiée par sous-étapes saisonnières, actualisation ajustée à la durée réelle des pas. Détails, hyperparamètres et justifications dans [note_methodo_r1.pdf](#).

Les six politiques comparées. Profit (récompense = profit par ferme) ; Pollution (récompense = moins la pollution) ; et quatre politiques équilibrées Bal-20k, Bal-100k, Bal-200k, Bal-400k (récompense = profit moins λ fois pollution, λ croissant). Entraînements de 600 à 800 épisodes selon les runs, même pipeline pour tous.

2. Question 1 : l'IA apporte-t-elle quelque chose ?

C'est la question préalable à toute la suite, et elle exige un point de comparaison extérieur : des stratégies **sans IA**. Deux stratégies constantes ont été évaluées, où chaque ferme applique le même paquet de pratiques chaque année, quoi qu'il arrive :

- **MaxProfit (sans IA)** : 100 % premium pour tout le monde, sur le paquet conventionnel vers lequel la politique Profit a elle-même convergé (CF à lame d'eau minimale, BAU, 2 saisons). C'est la lecture littérale de "tout le monde à fond sur ce qui rapporte".
- **MinPollution (sans IA)** : 100 % des pratiques vertes en continu (AWD doux, IPM, fertilisation durable, cultivar standard, 2 saisons).

Stratégie	Profit 10 fermes	Pollution	Profit 748 fermes	Pollution
Profit (IA)	484,7 k	0,0357	35,22 M	0,0420
MaxProfit (sans IA)	373,2 k	0,0365	27,69 M	0,0480
Bal-100k (IA)	372,8 k	0,0200	27,30 M	0,0326
MinPollution (sans IA)	18,1 k	0,0350	1,19 M	0,0460

Premier résultat : +30 % de profit à 10 fermes, +27 % à 748, par le seul timing. La stratégie MaxProfit n'échoue pas agronomiquement : ses sols restent sains (0,99) et ses rendements normaux (5,0 t/ha). Elle échoue économiquement, parce que 100 % de premium en permanence sature le marché et écrase le prix. La politique Profit adopte les mêmes pratiques agricoles, mais module le taux de premium (86 % en moyenne, pas 100 %) : elle sort du premium quand le prix casse et y revient ensuite. Toute sa valeur ajoutée est là.

Deuxième résultat, plus contre-intuitif : cocher toutes les pratiques vertes ne dépollue presque pas.

MinPollution ne réduit la pollution que de 4 % par rapport à MaxProfit (0,0365 vers 0,0350 à 10 fermes ; 0,0480 vers 0,0460 à 748), en sacrifiant 95 % du profit. Pendant ce temps, Bal-100k atteint le **même profit que MaxProfit avec 32 % de pollution en moins** à 748 fermes, et Bal-400k fait 7,4 fois le profit de MinPollution avec 2,5 fois moins de pollution. Les deux stratégies constantes sont dominées au sens de Pareto, aux deux échelles.


L'interprétation tient en une phrase : **dans ce modèle, dépolluer n'est pas une question de pratiques mais de déclenchement.** La pollution vient des pulvérisations ; ce qui compte est de pulvériser peu quand la pression ravageur le permet, ce que seule une politique qui lit l'état du système sait faire.

2.1 La preuve micro : les fermes suivent le marché

L'évaluation ferme par ferme (fichier `eval_per_farmer_peragent.xlsx`, matrices année x ferme) montre le mécanisme à l'oeuvre au niveau individuel. Sur un épisode de la politique Profit, on observe des cycles nets : les premières années, toutes les fermes sont en premium ; le prix se dégrade, les résultats s'écroulent, et la majorité bascule en standard ; le prix du premium se reconstitue, et le paysage rebascule en premium. Ces vagues d'adoption et de retrait, ferme par ferme, sont la signature visible de la coordination temporelle qui explique l'écart avec la stratégie constante.

3. Question 2 : peut-on piloter le compromis profit / pollution ?

Une fois établi que l'IA maximise correctement le profit, la question opérationnelle devient : peut-on lui faire viser autre chose, et avec quel contrôle ? Le levier testé est le poids λ dans la récompense "profit moins λ fois pollution".



Politique	Profit (10 fermes)	Pollution	Premium	AWD	IPM	Durable
Profit	484,7 k	0,0357	86 %	0 %	4 %	0 %
Bal-20k	479,5 k (99 %)	0,0351	82 %	12 %	4 %	4 %
Bal-100k	372,8 k (77 %)	0,0200 (-44 %)	32 %	37 %	30 %	30 %
Bal-200k	319,9 k (66 %)	0,0312	20 %	19 %	50 %	34 %
Bal-400k	63,4 k (13 %)	0,0268	2 %	0 %	91 %	48 %
Pollution	265,9 k (55 %)	0,0332	14 %	15 %	44 %	43 %

Le curseur lambda fonctionne, avec un seuil. En dessous d'environ 58 000 (valeur estimée par calcul sur les ordres de grandeur des deux termes), le terme de pollution est négligeable et la politique se comporte comme Profit (c'est le cas de Bal-20k). Au-delà, le compromis s'installe. A 10 fermes, Bal-100k est le point remarquable : pour -23 % de profit, -44 % de pollution, via un mix équilibré (environ un tiers de premium, d'AWD, d'IPM et de durable). Il domine même les politiques plus contraintes (200k, 400k) sur les deux axes à la fois à cette échelle.

L'échec instructif : la politique "pollution seule". Entraînée uniquement à minimiser la pollution, elle devrait être la meilleure sur cet axe. Elle ne l'est nulle part. Son premier entraînement avait convergé vers un optimum dégénéré (IPM seul, quasi aucune autre pratique) ; réentraînée avec un taux d'apprentissage réduit, elle adopte un mix plausible mais reste battue par Bal-100k sur son propre objectif (0,0332 contre 0,0200), et son transfert à 748 fermes est mauvais (0,0465, pire que la politique Profit). Hypothèses, détaillées dans [rapport_complet.pdf](#) :


- Signal trop plat** : la pollution varie peu et lentement entre actions ; le gradient d'apprentissage est faible et l'exploration s'effondre. Le terme de profit du Balanced agit comme un guide d'exploration (reward shaping) qui découvre au passage les régimes peu polluants.
- Attribution du mérite difficile** : la pollution d'une ferme dépend de ses pulvérisations passées et de la diffusion depuis les voisines ; le lien action vers récompense est retardé et brouillé.

- Externalité collective** : réduire sa pollution profite d'abord aux voisins (diffusion), ce qui affaiblit une récompense individuelle.
- Piège de la boucle ravageur** : sans incitation au maintien d'un agrosystème sain, le système dérive vers un régime haute pression / haute pulvérisation. Le profit, lui, force à garder le système sain, donc peu polluant : c'est pourquoi la politique pollution-seule fait plus d'IPM mais plus de pollution.

Recommandation opérationnelle : ne jamais utiliser l'objectif pollution seul ; travailler sur la famille Balanced, avec lambda proche de 100k pour un scénario "agriculture raisonnée" et 400k pour un scénario "priorité environnement".

4. Question 3 : est-ce que ça passe à l'échelle ?

Les six politiques, entraînées sur 10 fermes, ont été rejouées telles quelles sur la carte réelle : 748 fermes, grille spatiale 4 fois plus fine, sans un seul épisode de réentraînement. C'est un test exigeant : la politique n'a jamais vu ni cette carte, ni cette densité de voisinage, ni cette taille de marché.



Politique	Profit (748, greedy)	Pollution	Lecture
Profit	35,22 M	0,0420	référence
Bal-20k	30,11 M (85 %)	0,0471	dominée : lambda trop faible ne fait que dégrader
Bal-100k	27,30 M (77 %)	0,0326 (-22 %)	scénario "raisonné"
Bal-200k	17,89 M (51 %)	0,0281 (-33 %)	intermédiaire
Bal-400k	8,79 M (25 %)	0,0181 (-57 %)	scénario "environnement"
Pollution	15,98 M (45 %)	0,0465	dominée partout

Le transfert fonctionne, et la grande échelle assainit même la lecture. A 748 fermes, la frontière devient propre et monotone : Bal-100k, 200k et 400k échangent régulièrement du profit contre de la pollution. La dominance totale de

Bal-100k observée à 10 fermes ne se reproduit pas : elle tenait à l'environnement d'évaluation réduit, pas aux politiques. Fait notable, les politiques adaptent leur mix à la carte réelle (Bal-100k y passe à 79 % d'AWD et 70 % de durable, bien plus qu'à 10 fermes) : étant conditionnées à l'état, elles modulent leurs pratiques selon les fermes réelles, ce qui est exactement le comportement recherché.

La surprise : greedy et stochastique divergent fortement à grande échelle. En décision déterministe (greedy, l'action est la moyenne de la distribution), les chiffres sont ceux du tableau. En décision échantillonnée (stochastique), à 10 fermes rien ne change (écarts de 2 à 3 %) ; à 748 fermes, tout change :

- La politique Profit s'effondre de 35,2 M à 18,1 M (-49 %) : le bruit d'échantillonnage, multiplié par 748 fermes, casse la coordination premium collective.
- A l'inverse, les politiques très contraintes remontent : Bal-400k passe de 8,8 M à 14,4 M (+64 %), en devenant même légèrement plus verte. L'échantillonnage les sort d'un mode déterministe médiocre (effet de diversification type jeu de minorité).

Conséquence pratique : en déploiement, on joue la politique greedy, et les chiffres greedy sont la performance attendue. Mais l'écart greedy / stochastique doit devenir un indicateur de suivi standard : il mesure la fragilité de la coordination apprise, et il ne se voit qu'à l'échelle réelle.

5. Ce que l'IA a révélé du modèle Starfarm

Un agent qui optimise sans relâche finit par exploiter ou exposer les recoins du modèle. Trois découvertes de ce type, qui sont des retours directs pour l'équipe de modélisation.

5.1 La pollution ne vient que des pesticides. Dans le code actuel, seule la pulvérisation ajoute de la pollution (qui décroît puis diffuse vers les cellules voisines) ; ni l'irrigation (pas de méthane pour CF) ni la fertilisation (pas de ruissellement azoté) n'y contribuent. Conséquences : l'adoption d'AWD ou de fertilisation durable par les politiques "vertes" n'agit sur la pollution qu'indirectement, via la maîtrise de la pression ravageur ; et le résultat "MinPollution ne dépollue que de 4 %" doit se lire dans ce cadre. Si une version future du modèle fait contribuer l'eau et l'azote à la pollution, les conclusions de la section 3 devront être re-mesurées (le pipeline est prêt pour cela).

5.2 L'observation de rendement est aveugle en calendrier 3 saisons. Découvert en construisant la stratégie sans-IA "intensive" : en 3 saisons, l'observation de rendement lit 0 en permanence, alors que les récoltes ont bien lieu (le profit est là). Cause mécanique : le rendement de parcelle est remis à zéro à chaque semis, et l'instant de décision annuel tombe après un semis en calendrier 3 saisons, avant que la récolte ne l'ait renseigné. C'est un vrai défaut d'instrumentation : une politique qui choisirait 3 saisons perdrait une observation sur 18.

5.3 Aucune politique ne choisit jamais 3 saisons, et c'est peut-être lié. Sur les six politiques entraînées, le taux de choix "3 saisons" est exactement 0 %. Deux mécanismes mesurés peuvent l'expliquer : la dégradation du sol triple (0,015 par an au lieu de 0,005, la jachère disparaissant) et l'observation de rendement devient muette (5.2). Il reste à départager la part du signal agronomique réel et la part de l'artefact d'observation ; d'ici là, le rejet unanime des 3 saisons par l'IA ne doit pas être interprété comme une conclusion agronomique.

Au-delà de ces trois points, l'expérience El Farol du premium (section 2) est aussi une validation du modèle : la rétroaction prix-adoption du marché premium crée bien le problème de coordination qu'elle visait à représenter, suffisamment pour qu'une IA en tire un avantage de +27 à +30 %.

6. Limites de l'étude

- **Peu d'épisodes d'évaluation en réel** : un épisode par condition à 748 fermes (trois à 10 fermes en stochastique). Les écarts massifs (baselines, effondrement stochastique de Profit) sont robustes à ce bruit ; les écarts fins entre politiques voisines demanderaient des répétitions.
- **Entraînement uniquement à 10 fermes.** Le transfert à 748 est un résultat, mais rien ne dit qu'un entraînement (ou un affinage) directement à 748 fermes ne ferait pas mieux, notamment pour restaurer la coordination premium sous échantillonnage.

- **Choix de checkpoint hétérogène** : la politique Profit est évaluée sur son meilleur checkpoint (sélectionné par profit greedy), les autres sur leur checkpoint final, la sélection "best" n'ayant pas de sens pour un objectif différent du profit.
- **Un seul seed d'entraînement par politique**. La non-monotonie résiduelle de la frontière à 10 fermes (Bal-200k et 400k dominés localement) ressemble à des optima locaux ; du multi-seed trancherait.
- **Bruit d'exploration indépendant de l'état** : l'écart-type de la politique (`log_std global`) module l'écart greedy / stochastique ; une paramétrisation dépendante de l'état changerait sans doute la section 4.

7. Recommandations et suite

Pour l'exploitation des résultats : 1. Retenir la famille Balanced comme livrable : λ proche de 100k (77 % du profit, -22 à -44 % de pollution) en scénario raisonné, 400k en scénario environnement ; affiner éventuellement λ par balayage local (60k à 140k). 2. Déployer en greedy, et suivre l'écart greedy / stochastique comme indicateur de fragilité de la coordination. 3. Ecarter définitivement l'objectif pollution-seul.

Pour le modèle Starfarm : 4. Faire contribuer l'irrigation et la fertilisation à la pollution (ou documenter que la variable représente les seuls pesticides), puis re-mesurer la frontière. 5. Corriger l'observation de rendement en calendrier 3 saisons (lire la dernière récolte plutôt que la valeur courante remise à zéro au semis).

Pour la suite du travail RL : 6. Répéter les évaluations réelles (5 à 10 épisodes) pour quantifier la variance. 7. Tester un affinage (fine-tuning) à 748 fermes, en particulier pour la politique Profit sous échantillonnage. 8. Multi-seed sur les politiques équilibrées pour confirmer la forme de la frontière.

Annexe A : chronologie et leçons du cheminement

1. **Premiers pas (IPPO, décisions simultanées)**. Un premier pipeline PPO indépendant par agent a validé la connexion GAMA-Python et le cycle d'entraînement, mais s'est heurté à deux murs : les écritures dans la simulation via l'endpoint d'expressions du serveur GAMA rejettent les affectations directes, ce qui a imposé de passer par des appels d'actions GAML dédiés ; et surtout, une politique partagée avec décisions simultanées rendait toutes les fermes identiques, faisant s'effondrer le marché premium (problème El Farol).
2. **Décisions séquentielles**. L'introduction d'un tour de décision annuel en ordre aléatoire, où chaque ferme observe la part de premium déjà engagée, a permis la différenciation sans identifiant d'agent : c'est la clé de voûte du dispositif actuel.
3. **Passage à MAPPO et récompense densifiée**. Critique centralisé (information globale à l'entraînement seulement), récompense saisonnière par sous-étapes, actualisation ajustée à la durée réelle des pas : la convergence est devenue nette et reproductible.
4. **Récompense par agent contre récompense globale**. Les deux modes convergent, le mode par-agent facilitant l'attribution du mérite ; un run global prolongé à 800 épisodes a servi de référence de stabilité (rapport dédié).
5. **Analyse par fermier**. L'export Excel par ferme et par année a montré les cycles premium (section 2.1) et permis de vérifier que les fermes rentables ne le sont pas par taille mais par timing.
6. **Test de scalabilité**. Premier passage sur la carte réelle : le transfert 10 vers 748 fonctionne, ce qui a ouvert toute la campagne d'évaluation à grande échelle.
7. **Objectifs multiples**. Ajout des modes de récompense pollution et équilibré (sans toucher à la structure du code : un entier de mode et un poids λ côté GAML). Le premier entraînement pollution a convergé vers un optimum dégénéré, corrigé par un réentraînement à taux d'apprentissage réduit ; leçon : les objectifs à signal plat demandent des réglages plus prudents.
8. **Balayage λ** . Trois entraînements supplémentaires (100k, 200k, 400k) ont tracé la frontière de la section 3.
9. **Evaluations stochastiques**. La comparaison greedy / échantillonné aux deux échelles a révélé la fragilité de la coordination à 748 fermes (section 4).
10. **Baselines sans IA**. Les deux stratégies constantes ont fermé la boucle en donnant aux résultats un point de comparaison extérieur (section 2), et ont révélé au passage le défaut d'observation du rendement en 3 saisons (section 5.2).

Incidents notables et corrections : une reprise d'entraînement mal configurée a écrasé un checkpoint (récupéré via sauvegarde, et un garde-fou de sauvegarde automatique a été ajouté au trainer) ; une erreur d'étiquette sur les premières figures Pareto ("haut-gauche = idéal" au lieu de haut-droite) a été corrigée ; une conclusion intermédiaire erronée ("pollution inélastique, plancher 0,0285", tirée de la seule politique pollution) a été invalidée par Bal-100k (0,0200) et retirée.

Annexe B : index des livrables

Rapports (dossier `rl/report/`) : - `rapport_bilan.pdf` : ce document. - `note_methodo_rl.pdf` : note technique RL en anglais (architecture, hyperparamètres, choix de conception), pour relecture par des experts. - `rapport_pareto.pdf` : balayage lambda et frontière, avec sections stochastiques. - `rapport_complet.pdf` : synthèse des 4 conditions d'évaluation et hypothèses sur l'échec de l'objectif pollution. - `rapport_objectifs.pdf`, `rapport_scalabilite.pdf`, `rapport_eval_par_fermier.pdf`, `rapport_peragent_vs_global.pdf` : rapports d'étape thématiques.

Données (dossier `rl/`) : - `eval_objectives_comparison_greedy10 / _stoch10 / _bigmodel / _stoch748 / _greedy748_pollution.xlsx` : les 6 politiques par condition (feuilles "comparaison" et "detail" année x ferme). - `eval_baselines_comparison_simple / _full.xlsx` : stratégies constantes sans IA. - `eval_per_farmer_peragent.xlsx` : matrices année x ferme (rewards, cultivars, actions).

Code : voir `rl/README.md` (pipeline, configs, échelles, artefacts).