

Rapport complet : objectifs de récompense, greedy vs stochastique, deux échelles

Projet Starfarm, apprentissage par renforcement multi-agents. Juillet 2026


Protocole

Six politiques (même pipeline MAPPO, seul l'objectif de récompense change) sont évaluées dans **quatre conditions** croisées :

- **Échelle** : simulation *simple* (10 fermes) et *réelle* (748 fermes, sans réentraînement).
- **Décision** : *greedy* (action déterministe = moyenne de la gaussienne) et *stochastique* (action échantillonnée dans la distribution de la politique).

Le modèle **pollution a été ré-entraîné** (lr abaissé à 1e-4) ; ses résultats remplacent partout l'ancien run dégénéré. En stochastique 10 fermes, 3 épisodes sont moyennés (moy ± écart-type) ; les autres conditions sont à 1 épisode (voir Réserves). La récompense d'éval est toujours le **profit global réel** et la **pollution moyenne**, quel que soit le mode entraîné. Données détaillées dans eval_objectives_comparison_*.xlsx.

Résultats consolidés



Profit global (sur 25 ans) et pollution moyenne, par condition :

Politique	Simple greedy	Simple stoch.	Réel greedy	Réel stoch.
Profit	485 k / 0,0357	472 k / 0,0348	35,2 M / 0,0420	18,1 M / 0,0406

Bal-20k	479 k / 0,0351	464 k / 0,0333	30,1 M / 0,0471	29,6 M / 0,0469
Bal-100k	373 k / 0,0200	379 k / 0,0207	27,3 M / 0,0326	22,9 M / 0,0316
Bal-200k	320 k / 0,0312	276 k / 0,0221	17,9 M / 0,0281	19,4 M / 0,0280
Bal-400k	63 k / 0,0268	150 k / 0,0207	8,8 M / 0,0181	14,4 M / 0,0191
Pollution	266 k / 0,0332	255 k / 0,0341	16,0 M / 0,0465	2,3 M / 0,0263

Enseignement 1 : greedy et stochastique se comportent très différemment à grande échelle

À **10 fermes**, greedy et stochastique sont quasi identiques pour les politiques rentables (écart de profit –2 à –3 %, faible variance) : les conclusions greedy des rapports précédents sont robustes à cette échelle.

À **748 fermes**, l'écart explose et il est **asymétrique** :

- Les politiques à fort premium **perdent** en stochastique : Profit **35,2 M -> 18,1 M (–49 %)**, Bal-100k 27,3 -> 22,9 M (–16 %). Le bruit d'échantillonnage casse la coordination premium collective (beaucoup de fermes basculent aléatoirement leur choix binaire).
- Les politiques contraintes / vertes **gagnent** en stochastique : Bal-400k **8,8 -> 14,4 M (+64 %)**, Bal-200k 17,9 -> 19,4 M (+9 %). L'échantillonnage les sort d'un **mode déterministe médiocre** (même mécanisme de diversification de type jeu de minorité déjà observé).

Conséquence pratique : en déploiement on joue la politique **greedy** (déterministe). Les chiffres *réel greedy* sont donc la performance réelle attendue ; le stochastique est surtout un diagnostic de la largeur de la distribution de la politique.

Enseignement 2 : la frontière de Pareto tient à grande échelle (greedy)

En *réel greedy*, la hiérarchie lambda est propre et monotone : Bal-100k (0,0326, 27,3 M) -> Bal-200k (0,0281, 17,9 M) -> Bal-400k (**0,0181**, 8,8 M). Le curseur lambda trace bien le compromis profit / pollution. **Recommandations de déploiement** :

- Bal-100k** : scénario « raisonné » (77 % du profit de Profit, –22 % de pollution).
- Bal-400k** : scénario « priorité environnement » (–57 % de pollution, 25 % du profit).

Enseignement 3 : le modèle pollution ré-entraîné reste le mauvais choix

Le ré-entraînement a **corrigé l'optimum dégénéré** vu auparavant : à 10 fermes, mix diversifié (IPM 44 %, durable 43 %, AWD 15 %), profit multiplié par ~6, et pollution (0,0332) enfin **sous** celle de Profit. Mais :

- il **ne bat toujours pas les Balanced** sur son propre objectif (0,0332 contre 0,0200 pour Bal-100k à 10 fermes) ;
- il **transfère mal** : en *réel greedy*, sa pollution (0,0465) est **pire que Profit** (0,0420) ; sa version stochastique atteint 0,0263 mais au prix d'un effondrement du profit (2,3 M, soit ~8 % de Bal-20k) et d'une variance élevée.

Autrement dit, la politique pollution-seule est **instable et non transférable**, dominée par les Balanced dans toutes les conditions de déploiement.

Pourquoi l'objectif « pollution seule » échoue (hypothèses)

La pollution n'est **ajoutée** que par les pulvérisations de pesticide, puis décroît (x0,9/jour) et **diffuse** vers les cellules voisines ; une boucle pollution -> pression ravageur -> pulvérisation existe. D'où :

1. **Signal trop plat** : récompense = `-pollution` (~0,03, faible variance entre actions) -> gradient faible, exploration effondrée, optimum local médiocre. Le terme de profit du Balanced fournit un gradient riche qui découvre incidemment les régimes peu polluants (reward shaping).
2. **État retardé et diffusé** : la pollution d'une ferme dépend de ses sprays passés *et* de l'import des voisins -> attribution de crédit difficile pour une récompense par fermier.
3. **Externalité collective** : réduire sa pollution profite surtout aux voisins (diffusion), ce qui plafonne le gradient d'une récompense purement individuelle.
4. **Piège de la boucle ravageur** : sans incitation à garder l'agro-système sain, la politique le laisse dériver vers un régime haute-pression / haute-pulvérisation. Le profit maintient au contraire le système sain, donc peu polluant. Ceci explique que la pollution-seule ait *plus* d'IPM mais *plus* de pollution.
5. **Diffusion dominante à l'échelle** : à 748 fermes la grille est fine (voisinage dense) -> l'import de pollution voisine domine, ce qui explique la dégradation spécifique au passage à l'échelle.

Fil conducteur : le profit agit comme **guide d'exploration** qui maintient un régime sain où la pollution est basse ; l'objectif mono-critère retire ce guide. Conclusion : ne jamais utiliser l'objectif pollution seul, préférer un Balanced à lambda élevé.

Réserves

- **Un seul épisode** en *réel* (les deux échelles/modes sauf simple stochastique, à 3 épisodes) : les points *réels* sont indicatifs, la variance n'y est pas quantifiée. Les écarts fins (ex. Bal-200k vs Bal-100k) sont à confirmer.
- Le *réel greedy* des 5 politiques inchangées provient du run précédent (mêmes modèles), fusionné avec le point pollution ré-entraîné mesuré séparément.
- L'écart greedy/stochastique est en partie gouverné par `log_std` (indépendant de l'état) : une politique à `log_std` élevé diverge davantage sous échantillonnage.
- Limite modèle (à remonter) : la pollution ne dépend que des pesticides ; ni l'irrigation (AWD, méthane) ni la fertilisation (ruissellement azote) n'y contribuent.