

Rapport d'état — Projet MARL Starfarm


État complet du projet : architecture, chronologie des expériences, analyse du run en cours. (Données arrêtées à l'épisode 360/400 du run en cours — le run a progressé pendant la rédaction.)

1. Résumé exécutif

Le projet a construit, de zéro, une chaîne complète d'apprentissage par renforcement multi-agent (MARL) sur la simulation rizicole Starfarm (GAMA), avec l'objectif de **maximiser le profit global des fermiers**. Après quatre générations d'expériences, l'état actuel est :

- [OK] **Pipeline industriel complet** : GAMA ↔ Python optimisé (~70× moins d'allers-retours), entraînement MAPPO, évaluation contre baselines, checkpointing du meilleur modèle, rapports reproductibles.
- [OK] **Le RL apporte une valeur irremplaçable** : dans l'environnement scénario (crise des ressources, 25 ans), la politique apprise atteint **~434k de profit** là où la *meilleure* stratégie fixe plafonne à **220k (+97 %)** et où les pratiques conventionnelles **perdent de l'argent**.
- [obs] **Découverte du run en cours** : la politique **stochastique** surpasse la politique **déterministe (greedy)** en fin d'entraînement — un effet de la **diversification face au marché couplé** (voir §5).


2. Architecture technique actuelle



Composant	Valeur actuelle
Algorithme	MAPPO (CTDE) : acteurs décentralisés à poids partagés + critique centralisé
Action (par fermier, annuelle)	Box (6) continu : irrigation CF/AWD + quantité, pesticide BAU/IPM, engrais BAU/durable, cultivar standard/premium, 2/3 saisons
Observation (par fermier)	Box (17) : 4 état ferme + pollution/salinité + 2 descripteurs statiques (nb parcelles, surface) + 2 signaux marché globaux (part premium, prix) + 6 dernière action + indice d'année
Récompense	profit global d'équipe, versée par sous-pas saisonnier (delta de profit par fenêtre de 122 j) — décisions annuelles (semi-MDP)
Horizon	25 années simulées (scénario 2025-2050), $\gamma = 0.97$ annuel (prorata par sous-pas)

Environnement	météo PESSIMISTE + marché CRISE (eau +5 %/an, engrais +4 %/an), générateur stochastique
Stabilisation	normalisation adaptative de la valeur, décroissance d'entropie (0.01→0.001), KL early-stop (0.03), critique 256, éval greedy périodique pilotant le best-checkpoint


3. Chronologie : quatre générations d'expériences



Gen	Setup	Résultat	Enseignement
1	IPPO, Box(4) (irrigation/pesticide/engrais), env fixe, 10 ans	politique ≈ meilleur baseline constant (285k ≈ 284k) ; la courbe d'entraînement décline	L'optimum était quasi constant (« BAU intensif ») → presque rien à apprendre
2	+ cultivar & saisons → Box(6)	apprend (+17 %) mais sous le plafond (320k < 431k du baseline premium)	Les bons leviers rendent le problème apprenable ; le riz premium renverse l'optimum ; IPPO plafonne (attribution de crédit)
3	MAPPO + obs marché + env scénario crise + 25 ans	435k vs 220k pour le meilleur constant (+97 %) ; les stratégies conventionnelles perdent (−154k à −305k)	Le critique centralisé + l'adaptativité font du RL un outil irremplaçable en environnement difficile
4 (en cours)	+ pack efficacité : récompense saisonnière, obs 17, value-norm, entropy decay, KL-stop, critique 256, éval greedy	pic greedy 434k dès l'ép. 224 ; divergence stochastique/greedy ensuite (§5)	Convergence plus rapide et mesurable ; découverte de l'effet « diversification »

Note de lecture : Gen 1-2 (env fixe, 10 ans) et Gen 3-4 (env crise, 25 ans) ne sont pas comparables entre elles en valeur absolue.

4. Le run en cours (épisode 360/400)




Phase 1 — montée rapide et quasi monotone (ép. 0 → 224). L'éval greedy (la *vraie* performance, sans bruit d'exploration) progresse de **174k → 434k** : +149 % en 224 épisodes, avec une trajectoire 174 → 245 → 347 → 378 → 422 → 428 → **434k**. Le pic **égale le meilleur résultat du run précédent (435k)** mais il est atteint de façon *documentée et reproductible* (le run précédent n'avait pas d'éval périodique — on ne savait pas quand il était bon).

Phase 2 — divergence (ép. 224 → 360). Les évals greedy **redescendent** (369k, 356k, 363k, 359k, 351k) pendant que la courbe stochastique continue de monter (ma20 ≈ **435k**, max 449k). L'écart stochastique – greedy atteint ~80k. Analyse au §5.

Le filet de sécurité a fonctionné : le best-checkpoint est piloté par l'éval greedy → le modèle sauvegardé est celui du **pic (434k, ép. 224)**, pas la version dégradée actuelle. C'est exactement le scénario pour lequel ce mécanisme a été ajouté.

Comparaison des deux runs MAPPO (courbes stochastiques non directement comparables : obs 15 vs 17, bruit d'exploration différent)



Comparaison avec le run précédent (mode annuel, sans pack) : les courbes stochastiques ne sont pas directement comparables (observations 15 vs 17, bruit d'exploration différent), mais le run actuel fournit ce que l'ancien ne pouvait pas : une **mesure fiable de la vraie performance en continu** — et un pic certifié à 434k.

5. Le phénomène clé : stochastique > greedy

En fin de run, la politique **échantillonnée** (~435k en moyenne) bat nettement sa version **déterministe** (~355k). Ce n'est pas un artefact — c'est une propriété du problème :

1. **Le marché punit l'uniformité.** Le prix du riz premium s'effondre quand l'offre sature : la stratégie optimale n'est pas « tous en premium » mais un **portefeuille diversifié** (une partie des fermiers en premium, l'autre en standard).
2. **L'acteur partagé déterministe ne peut pas se différencier.** Les 10 fermiers partagent les mêmes poids ; à observations proches, le mode greedy produit des décisions **identiques** → comportement uniforme → saturation → profit dégradé.
3. **Le bruit d'échantillonnage brise la symétrie.** En mode stochastique, des tirages différents envoient naturellement une partie des fermiers de chaque côté des seuils (premium/standard...) → diversification → meilleurs prix. PPO optimise précisément le retour de la politique *stochastique* — c'est ce qu'il a appris à exploiter.

Conséquences pratiques : - Pour *déployer* la politique, le mode **stochastique** est légitime (c'est l'objectif optimisé) — ou utiliser le **best-checkpoint greedy** (434k) si l'on exige du déterminisme. - Pour permettre une diversification *déterministe*, il faudrait que les fermiers puissent se distinguer davantage : identifiant d'agent dans l'observation, ou poids non partagés — piste de la prochaine itération.

6. Infrastructure et optimisations (acquis du projet)

- **Pont embarqué** : PetzAgent vit dans le monde Starfarm (l'approche co-modèle initiale gelait l'horloge → récompense nulle ; diagnostiqué et corrigé).
- **Batching nb_step** : saut groupé calibré par la mémoire des longueurs d'année + finition fine → **~70× moins d'allers-retours** GAMA↔Python (paramètre natif de `gama_client`, bibliothèque intacte).

- **Récompense saisonnière** : delta de profit par fenêtre de 122 j à coût de simulation nul ; le critique apprend sur une chaîne $\sim 4\times$ plus dense (GAE à gamma variable).
- **Injection d'actions** par action-call (l'endpoint `expression` refuse les affectations) ; mode récompense global/par-fermier toggleable.
- **Outillage** : éval contre baselines (`eval_policy.py`), logs année par année, configs par expérience, rapports PDF reproductibles.

7. État du dépôt et livrables

- **Branche `stage-marl`** : commit `b0cb7f0` (étape Box(6)/IPPO) au-dessus du dernier commit du collègue (`ace90fe`, scénarios) — rebase propre, **rien n'est pushé**.
- **Non committé** (working tree) : toute la génération 3-4 — MAPPO, obs 17, récompense saisonnière, pack efficacité. À *committer une fois le run terminé et évalué*.
- **Livrables** : `rapport_marl_starfarm.pdf` (Gen 1), `rapport_marl_box6.pdf` (Gen 2), présentation vulgarisée (`presentation3.pptx`), et ce rapport d'état.

8. Prochaines étapes proposées

1. **Fin du run (ép. 400)** : éval finale du best-checkpoint vs baselines (`eval_policy.py config_mappo2.yaml --best`), + éval **stochastique** pour quantifier proprement l'écart greedy/échantillonné.
2. **Committer la génération MAPPO** sur `stage-marl`.
3. **Briser la symétrie proprement** : identifiant d'agent (one-hot) dans l'observation pour permettre la diversification déterministe — réponse structurelle au phénomène du §5.
4. **Récompense durabilité** (émissions, eau, sol) : transformer « max profit » en arbitrage rendement/durabilité — en attente des besoins du collègue.
5. (*Option*) Parallélisme multi-serveurs GAMA ($N \text{ threads} \times N \text{ ports}$) si de nombreux runs sont prévus.