

# Balayage lambda — frontière profit <-> pollution (6 politiques)

Projet Starfarm — MARL - 8 juillet 2026


## Contexte

Suite du rapport « objectifs » : le point Balanced à  $\lambda=20000$  se comportait comme Profit ( $\lambda$  sous le seuil de bascule estimé  $\sim 58\,000$ ). Trois entraînements supplémentaires ont été lancés à **lambda = 100k / 200k / 400k** (600 épisodes chacun, même pipeline). Les **6 politiques** sont rejouées en greedy (25 ans, mêmes fermes, même ordre de décision) et mesurées sur les deux axes. Le modèle **pollution a été ré-entraîné** ( $lr\ 1e-4$ ) ; ses valeurs à jour figurent partout. Détails dans `eval_objectives_comparaison_*.xlsx`.

**Choix de checkpoint** : la sélection `best_` étant pilotée par le *profit* greedy, elle n'a de sens que pour la politique Profit ; les politiques pollution/balanced sont évaluées sur leur **checkpoint final** (convergé sous leur propre objectif, non biaisé profit).

## Résultats (greedy, 10 fermes)

Objectifs de récompense — profit vs pollution | mode GREEDY (deterministic), 1 épisode(s)/politique, 10 fermes



| Politique | Profit global   | Pollution moy. | Premium | AWD  | IPM | Durable |
|-----------|-----------------|----------------|---------|------|-----|---------|
| Profit    | 484,7 k€        | 0,0357         | 86 %    | 0 %  | 4 % | 0 %     |
| Bal-20k   | 479,5 k€ (99 %) | 0,0351 (−2 %)  | 82 %    | 12 % | 4 % | 4 %     |

|           |                 |                |      |      |      |      |
|-----------|-----------------|----------------|------|------|------|------|
| Bal-100k  | 372,8 k€ (77 %) | 0,0200 (-44 %) | 32 % | 37 % | 30 % | 30 % |
| Bal-200k  | 319,9 k€ (66 %) | 0,0312 (-13 %) | 20 % | 19 % | 50 % | 34 % |
| Bal-400k  | 63,4 k€ (13 %)  | 0,0268 (-25 %) | 2 %  | 0 %  | 91 % | 48 % |
| Pollution | 265,9 k€ (55 %) | 0,0332 (-7 %)  | 14 % | 15 % | 44 % | 43 % |

## Trois enseignements majeurs

**1. Bal-100k est le point d'équilibre remarquable — il domine au sens de Pareto.** Pour **-23 % de profit**, il obtient **-44 % de pollution** (0,0357 -> 0,0200). Il fait *mieux que toutes les politiques plus « vertes »* sur les DEUX axes à la fois : plus de profit ET moins de pollution que Bal-200k, Bal-400k et Pollution. Sa recette est un **mix** : ~1/3 premium, ~1/3 AWD, ~1/3 IPM, ~1/3 durable.

**2. La politique « pollution pure », même ré-entraînée, reste dominée.** Le ré-entraînement (lr 1e-4) a corrigé l'optimum dégénéré « IPM-seul » du run précédent : à 10 fermes elle adopte enfin un mix (IPM 44 %, durable 43 %, AWD 15 %) et sa pollution (0,0332) passe sous celle de Profit. Mais elle **ne bat toujours pas Bal-100k** (0,0200) sur son propre objectif. Sans le signal de profit comme **guide d'exploration** (reward shaping), elle converge vers un régime médiocre plutôt que vers les vrais leviers : c'est Bal-100k, pas Pollution, qui dépollue le mieux.

**3. Correction du rapport précédent.** La conclusion « pollution largement inélastique, plancher ~0,0285 » — fondée sur la politique pollution seule — était **fausse** : Bal-100k atteint **0,0200**. La pollution est bien pilotable (-44 %), mais par une *combinaison* de pratiques qu'une récompense mono-objectif mal guidée ne trouve pas.


## Lecture de la frontière

- La frontière utile est **fortement non linéaire** : de lambda=20k à 100k on achète -42 points de pollution pour -22 points de profit ; au-delà de 100k on *perd* sur les deux axes (les politiques 200k/400k sont dominées — probablement des optima locaux d'entraînement, la non-monotonie le suggère).
- Recommandation opérationnelle : lambda ~ 100k** est le réglage à retenir pour un scénario « agriculture raisonnée ». Affiner éventuellement par un balayage local (60k–140k).

## Validation à grande échelle — simulation réelle (748 fermes), greedy

Les 6 politiques (entraînées sur 10 fermes) ont été rejouées **sans réentraînement** sur le modèle spatial réel (simple\_spatial\_data=false, **748 fermes**). Détails dans eval\_objectives\_comparison\_bigmodel.xlsx.

### Trois objectifs de récompense — profit vs pollution (politique per-fermier, éval greedy)



Note : sur cette figure le point Pollution correspond à l'ancien run ; la valeur du tableau ci-dessous est le modèle ré-entraîné.

| Politique       | Profit global   | (% Profit)  | Pollution moy. | (vs Profit)            |
|-----------------|-----------------|-------------|----------------|------------------------|
| <b>Profit</b>   | <b>35,22 M€</b> | 100 %       | 0,0420         | réf.                   |
| Bal-20k         | 30,11 M€        | 85 %        | 0,0471         | <b>+12 % (dominée)</b> |
| <b>Bal-100k</b> | 27,30 M€        | <b>77 %</b> | 0,0326         | <b>−22 %</b>           |
| <b>Bal-200k</b> | 17,89 M€        | 51 %        | 0,0281         | <b>−33 %</b>           |
| <b>Bal-400k</b> | 8,79 M€         | 25 %        | <b>0,0181</b>  | <b>−57 %</b>           |
| Pollution       | 15,98 M€        | 45 %        | 0,0465         | <b>+11 % (dominée)</b> |

Ce que la grande échelle change et confirme :


- **La frontière devient propre et monotone** : à 748 fermes, Bal-100k -> 200k -> 400k échangent régulièrement du profit contre de la pollution (−22 % / −33 % / −57 %). Le curseur lambda fonctionne comme prévu — la dominance totale de Bal-100k observée à 10 fermes ne se reproduit pas : elle tenait à l'environnement d'évaluation réduit, pas aux politiques elles-mêmes.
- **Deux résultats robustes aux deux échelles** : (1) la politique **Pollution reste dominée** (0,0465, au-dessus de Profit) — le ré-entraînement l'a sortie de la dégénérescence mais pas rendue compétitive ; (2) **Bal-100k conserve ~77 % du profit** aux deux échelles.
- **Bal-20k est dominée à grande échelle** (moins de profit ET plus de pollution que Profit) : lambda trop faible ne fait que dégrader, il n'équilibre rien.
- Les mix d'actions s'adaptent à la carte réelle (Bal-100k : AWD 79 %, durable 70 % — bien plus qu'à 10 fermes) : la politique étant conditionnée à l'état, elle module ses pratiques selon les fermes réelles.

**Recommandation finale (greedy) :** lambda~100k pour un scénario « raisonné » (77 % du profit, –22 % de pollution), lambda~400k pour un scénario « priorité environnement » (–57 % de pollution en gardant 25 % du profit).

Décisions stochastiques — simulation simple (10 fermes)

Mêmes politiques, mais l'action est **échantillonnée** dans la distribution de la politique (au lieu de la moyenne greedy). 3 épisodes, moyenne ± écart-type.

Objectifs de récompense — profit vs pollution | mode STOCHASTIC (sampled), 3 épisode(s)/politique, 10 fermes



| Politique | Profit global       | Pollution moy.      | Premium | AWD  | IPM  | Durable |
|-----------|---------------------|---------------------|---------|------|------|---------|
| Profit    | 472,4 k€<br>(±1,7)  | 0,0348<br>(±0,0012) | 83 %    | 1 %  | 9 %  | 1 %     |
| Bal-20k   | 463,8 k€<br>(±3,8)  | 0,0333<br>(±0,0008) | 77 %    | 12 % | 9 %  | 8 %     |
| Bal-100k  | 378,9 k€<br>(±3,7)  | 0,0207<br>(±0,0008) | 35 %    | 37 % | 30 % | 33 %    |
| Bal-200k  | 276,4 k€<br>(±25,2) | 0,0221<br>(±0,0011) | 17 %    | 22 % | 50 % | 41 %    |
| Bal-400k  | 150,5 k€<br>(±16,0) | 0,0207<br>(±0,0013) | 9 %     | 12 % | 88 % | 45 %    |
| Pollution | 255,1 k€<br>(±13,2) | 0,0341<br>(±0,0014) | 18 %    | 14 % | 43 % | 43 %    |

- Pour les politiques rentables, greedy ~ stochastique (Profit 485 -> 472 k, -2,5 % ; Bal-100k quasi identique) avec une variance faible : les conclusions greedy sont robustes.
- **Exception : Bal-400k et Bal-200k s'améliorent en stochastique** — Bal-400k passe de 63 k (greedy) à **150 k (+137 %)** et devient plus verte (0,0268 -> 0,0207). L'échantillonnage sort ces politiques très contraintes d'un mode déterministe médiocre (diversification de type jeu de minorité). Contrepartie : leur variance est bien plus élevée (Bal-200k ±25 k).

## Décisions stochastiques — simulation réelle (748 fermes)




| Politique       | Profit global   | Pollution moy. | Premium | AWD  | IPM  | Durable |
|-----------------|-----------------|----------------|---------|------|------|---------|
| Profit          | 18,07 M€        | 0,0406         | 73 %    | 2 %  | 30 % | 22 %    |
| Bal-20k         | 29,63 M€        | 0,0469         | 92 %    | 0 %  | 3 %  | 1 %     |
| Bal-100k        | 22,89 M€        | 0,0316         | 38 %    | 70 % | 26 % | 69 %    |
| Bal-200k        | 19,45 M€        | 0,0280         | 34 %    | 31 % | 80 % | 25 %    |
| <b>Bal-400k</b> | <b>14,43 M€</b> | <b>0,0191</b>  | 18 %    | 38 % | 88 % | 32 %    |
| Pollution       | 2,27 M€         | 0,0263         | 1 %     | 0 %  | 80 % | 25 %    |

- Ici greedy et stochastique divergent fortement (contrairement à 10 fermes). Profit chute de **35,2 M (greedy) à 18,1 M (stoch, -49 %)** : le bruit d'échantillonnage casse la coordination premium collective de la politique la plus rentable.
- À l'inverse, les politiques contraintes **gagnent** au sampling : Bal-400k 8,8 -> **14,4 M (+64 %)**, Bal-200k 17,9 -> 19,4 M. Même mécanisme qu'à 10 fermes, mais amplifié par l'échelle (voisinage plus dense, coordination plus fragile).

- **Conséquence pratique** : en déploiement on joue le **greedy** (déterministe) ; les chiffres greedy réels sont la performance attendue. Le stochastique reste un diagnostic de la largeur de la distribution de la politique.

## Synthèse — quatre conditions

Frontière profit / pollution — 4 conditions (haut-droite = idéal ; pollution ré-entraîné)



La figure superpose les frontières greedy/stochastique aux deux échelles (haut-droite = idéal, pollution ré-entraîné partout). Message d'ensemble : **le curseur lambda pilote un vrai compromis profit/pollution robuste** (Bal-100k raisonné, Bal-400k vert), l'objectif pollution-seul est à éviter, et l'écart greedy/stochastique — négligeable à 10 fermes — devient un facteur de premier ordre à 748 fermes.

## Réserves

- **Un seul épisode en réel** (les deux échelles/modes sauf simple stochastique, à 3 épisodes) : les points *réels* sont indicatifs, leur variance n'est pas quantifiée.
- Le *réel greedy* des 5 politiques inchangées provient du run précédent (mêmes modèles), fusionné avec le point pollution ré-entraîné mesuré séparément.
- L'écart greedy/stochastique est en partie gouverné par `log_std` (indépendant de l'état) : une politique à `log_std` élevé diverge davantage sous échantillonnage.
- Limite modèle (à remonter) : la pollution n'est ajoutée que par les pesticides ; ni l'irrigation (AWD, méthane) ni la fertilisation (ruissellement azote) n'y contribuent — l'adoption d'AWD/durable par les politiques vertes agit donc surtout *via* la maîtrise de la pression ravageur, pas directement.