

Balayage lambda — frontière profit <-> pollution (6 politiques)

Projet Starfarm — MARL - 2 juillet 2026


Contexte

Suite du rapport « objectifs » : le point Balanced à lambda=20000 se comportait comme Profit (lambda sous le seuil de bascule estimé ~58 000). Trois entraînements supplémentaires ont été lancés à **lambda = 100k / 200k / 400k** (600 épisodes chacun, même pipeline). Les **6 politiques** sont rejouées en greedy (25 ans, mêmes fermes, même ordre de décision) et mesurées sur les deux axes. Détails par fermier/année dans `eval_objectives_comparison.xlsx`.

Choix de checkpoint : la sélection `best_` étant pilotée par le *profit* greedy, elle n'a de sens que pour la politique Profit ; les politiques pollution/balanced sont évaluées sur leur **checkpoint final** (convergé sous leur propre objectif, non biaisé profit).

Résultats

Trois objectifs de récompense — profit vs pollution (politique per-fermier, éval greedy)



Politique	Profit global	Pollution moy.	Premium	AWD	IPM	Durable
Profit	484,7 k€	0,0357	86 %	0 %	4 %	0 %
Bal-20k	479,5 k€ (99 %)	0,0351 (−2 %)	82 %	12 %	4 %	4 %

Bal-100k	372,8 k€ (77 %)	0,0200 (–44 %)	32 %	37 %	30 %	30 %
Bal-200k	319,9 k€ (66 %)	0,0312 (–13 %)	20 %	19 %	50 %	34 %
Bal-400k	63,4 k€ (13 %)	0,0268 (–25 %)	2 %	0 %	91 %	48 %
Pollution	40,7 k€ (8 %)	0,0376 (+5 %)	0 %	0 %	92 %	4 %

Trois enseignements majeurs

1. Bal-100k est le point d'équilibre remarquable — il domine au sens de Pareto. Pour –23 % de profit, il obtient –44 % de pollution (0,0357 -> 0,0200). Il fait *mieux que toutes les politiques plus « vertes »* sur les DEUX axes à la fois : plus de profit ET moins de pollution que Bal-200k, Bal-400k et Pollution. Sa recette est un **mix** : ~1/3 premium, ~1/3 AWD, ~1/3 IPM, ~1/3 durable — c'est la *combinaison* AWD + durable + IPM qui réduit la pollution, pas une pratique isolée.

2. La politique « pollution pure » échoue sur son propre objectif. Elle s'enferme dans un optimum local dégénéré : 92 % d'IPM, rien d'autre (pas d'AWD, 4 % durable) — et sa pollution (0,0376) est *pire que celle de la politique Profit*. Sans le signal de profit, l'exploration s'effondre (production quasi nulle -> gradient très plat) et elle ne découvre jamais les leviers efficaces. **Le terme de profit dans la récompense équilibrée agit comme un guide d'exploration** (reward shaping) : c'est Bal-100k, pas Pollution, qui trouve comment dépolluer.

3. Correction du rapport précédent. La conclusion « pollution largement inélastique, plancher ~0,0285 » — fondée sur la politique pollution seule — était **fausse** : Bal-100k atteint **0,0200**. La pollution est bien pilotable (–44 %), mais par une *combinaison* de pratiques qu'une récompense mono-objectif mal guidée ne trouve pas.

Lecture de la frontière

- La frontière utile est **fortement non linéaire** : de $\lambda=20k$ à 100k on achète –42 points de pollution pour –22 points de profit ; au-delà de 100k on *perd* sur les deux axes (les politiques 200k/400k sont dominées — probablement des optima locaux d'entraînement, la non-monotonie le suggère).
- Recommandation opérationnelle : $\lambda \sim 100k$** est le réglage à retenir pour un scénario « agriculture raisonnée ». Affiner éventuellement par un balayage local (60k–140k).

Réserves

- Un épisode greedy par politique** : la variance inter-épisodes du profit est faible (CV ~0,4 % mesuré), celle de la pollution n'a pas été quantifiée — les écarts fins (ex. 0,0268 vs 0,0312) sont à confirmer par quelques épisodes de plus.
- La non-monotonie en λ (200k/400k pires que 100k sur la pollution) indique des **optima locaux** : relancer ces λ avec d'autres graines départagerait « vrai compromis » et « échec d'entraînement ».
- Question modèle pour le collègue : quels mécanismes de `pollution_level` rendent le combo **AWD + durable** si efficace, là où l'IPM seul ne suffit pas ?