

Récompense par fermier vs récompense globale — comparaison MAPPO

Projet Starfarm — apprentissage par renforcement multi-agents *Rapport de comparaison - 16 juin 2026 (màj : run global prolongé à 800 épisodes)*

1. Question posée

Pour maximiser le **profit global** (somme des profits annuels de tous les fermiers) dans un environnement de marché couplé, vaut-il mieux entraîner chaque fermier avec :

- une **récompense globale** (« équipe ») — tout le monde reçoit le même signal $r = \text{somme des profits de tous les fermiers}$; ou
- une **récompense par fermier** — chaque fermier reçoit *son propre* profit comme signal, le critique restant centralisé (il prédit le retour moyen par fermier, donc l'avantage de chaque fermier = son retour propre relativement à cette base commune) ?

Intuition classique : la récompense globale aligne directement les agents sur l'objectif et devrait gagner. **Le résultat est l'inverse.**

2. Protocole — strictement comparable



Les deux entraînements partagent **tout** sauf le mode de récompense :

Paramètre	Valeur (identique aux deux runs)
Algorithme	MAPPO (acteur partagé décentralisé + critique centralisé)
Environnement	Scénario de crise (météo pessimiste, marché en crise), 2025–2050
Horizon	25 ans / épisode - récompense par saison, décisions annuelles
Décisions	Séquentielles, ordre aléatoire (signal de marché dynamique)
Espace d'action	Box (6) (irrigation + quantité, pesticide, fertilisant, cultivar, saisons)
Observation	18 variables (ferme locale + signaux de marché globaux)
Budget	Par fermier : 400 ép. - Globale : 800 ép. (prolongée pour borner l'asymptote) - pack efficacité (normalisation des valeurs, décroissance d'entropie, arrêt KL, critique élargi, éval greedy périodique)

Métrique de comparaison. L'évaluation périodique mesure le **vrai profit global** (infos["global_profit"], jouée en mode *greedy* sans bruit d'exploration) — la **même quantité** dans les deux runs, quel que soit le signal d'entraînement. La comparaison est donc parfaitement « pommes contre pommes ».

Note de fiabilité : le run *global* (saved_models_mappo3) est une course propre de 400 épisodes. Le run *par fermier* (saved_models_mappo3_peragent) a subi un incident de reprise de checkpoint au milieu (corrigé) ; le pic d'origine à l'épisode 74 a bien été obtenu *from-scratch* avant l'incident, et la reprise a maintenu le même plateau. Les conclusions ne dépendent pas de l'incident.

3. Résultat




Mesure (profit global vrai, 25 ans)	Par fermier (400 ép.)	Globale (800 ép.)	Écart
Meilleur greedy	470,8 k (ép 74)	378,2 k (ép 724)	+24 %
Greedy final	448,0 k	373,6 k (ép 799)	+20 %
Plateau (dernier quart)	443,0 k	365,9 k	+21 %

Baseline constant (réf., même env)	~220 k	~220 k	—
------------------------------------	--------	--------	---

Trois lectures, une même conclusion : **la récompense par fermier domine la récompense globale sur l'objectif global lui-même**, d'environ **+20 à +25 %** sur les trois mesures. Le run global prolongé à 800 épisodes a refermé une partie de l'écart (il était de +51 % au snapshot de 400 ép.) mais **plafonne ~20 % en dessous** du plateau par-fermier.

Efficacité d'échantillonnage — l'avantage décisif. La récompense par fermier atteint son plateau (~470 k) dès **l'épisode 74** ; la récompense globale, prolongée à **800 épisodes**, ne plafonne qu'à **~375 k** et seulement vers **l'épisode 720**. Autrement dit, le signal par-fermier atteint un résultat **plus haut** en **~10x moins d'épisodes**.



4. Pourquoi le profit individuel maximise mieux le profit collectif

Deux mécanismes se cumulent, propres à ce problème :

Attribution du mérite (credit assignment). Avec la récompense globale, chaque fermier doit apprendre à travers le bruit des 9 autres : si le profit collectif monte, est-ce grâce à *mon* action ou à celle d'un voisin ? Le gradient de chaque agent est pollué par les décisions des autres → apprentissage lent et bruité. La récompense par fermier donne à chacun un signal **propre, à faible variance** (son profit) → gradient net → apprentissage rapide et stable.

Le marché récompense la diversité (jeu de minorité / El Farol). Le prix premium chute si trop de fermiers produisent du riz premium. L'optimum collectif est donc **hétérogène** (un sous-ensemble en premium, le reste en standard). Des agents intéressés à leur seul profit se **différencient naturellement** : dès que le premium est saturé, le fermier suivant a intérêt à rester standard. Une politique partagée entraînée sur un signal commun tend au contraire vers un comportement **uniforme**, que le marché pénalise. Les décisions séquentielles en ordre aléatoire (signal de marché dynamique) fournissent exactement le mécanisme de coordination qui permet à la politique par fermier de diversifier.

Autrement dit : ici, « chacun pour soi » sur un marché bien conçu produit un meilleur résultat collectif que « tous pour le total », parce que le total est non-additif (couplé par le prix) et récompense l'hétérogénéité.

5. Réserves et honnêteté méthodologique

- **Asymptote globale bornée (run prolongé à 800 ép.).** Le run global a été poussé à 800 épisodes : il converge vers un plateau de **~375 k** atteint vers l'épisode 720 (le creux vers l'ép. 424 vient de la ré-augmentation volontaire du pas d'apprentissage à la reprise). L'écart avec le par-fermier s'est donc réduit (de +51 % au snapshot de 400 ép. à +24 %) mais **ne se referme pas** : la récompense globale plafonne ~20 % plus bas, malgré un budget doublé. Les conclusions sur l'**efficacité** (~10x) et sur l'**asymptote** (par-fermier supérieur) sont désormais solides, plus seulement extrapolées.
- **Risque théorique de la récompense par fermier : la « tragédie des communs ».** Des agents égoïstes pourraient surexploiter une ressource partagée. Ici ce n'est *pas* observé (le profit global est plus haut, pas plus bas), parce que le couplage de marché passe par le **prix** (négatif pour l'uniformité) et non par une ressource physique épuisable partagée. Si une telle ressource était ajoutée au modèle, il faudrait re-vérifier.
- **Baseline constant** (~220 k) repris de la mesure Gen 3 dans le même environnement de crise (valeur indicative, non ré-évaluée pour ce run précis). Les deux politiques apprises battent largement toute stratégie fixe — le RL reste irremplaçable dans cet environnement.

6. Conclusion et recommandation

Par fermier	Globale
Profit global ~470 k (400 ép.) atteint	~375 k (800 ép.)
Vitesse plateau ép. 74 d'apprentissage	plateau ép. ~720 (~10x plus lent)
Signal propre, faible variance gradient	bruité (mérite mal attribué)
Comportement diversifié (premium/standard) émergent	tend vers l'uniforme

Recommandation : adopter la récompense par fermier comme configuration de référence pour la suite (config_mappo3_peragent.yaml, checkpoint best_starfarm_ippo.pth ~ 471 k). Elle maximise mieux l'objectif global *et* apprend bien plus vite, grâce à une meilleure attribution du mérite et à la diversification spontanée que le marché récompense.

Pistes immédiates : (1) *[fait]* le run global a été borné à 800 ép. (~375 k) ; (2) tester la robustesse de la politique par fermier sur un nombre de fermiers / une région différents (la transférabilité étant la raison du choix d'observations sans identifiant d'agent) ; (3) vérifier qu'aucune sur-exploitation ne se cache derrière le gain par-fermier (répartition premium/standard, qualité de sol en fin d'horizon).