

Entraînement MAPPO et test de transfert - 6 politiques x 4 cartes

Question posée. Les six politiques ont toutes été entraînées sur *une seule* carte : Dong Thap old simplifiée, 10 fermes. Ce rapport mesure ce qu'il en reste ailleurs - sur la carte réelle de la même province (748 fermes) et sur la nouvelle province Dong Thap (10 et 992 fermes), jamais vue à l'entraînement.

Réponse courte. Sur six politiques, **une seule transfère** de façon convaincante.

1. Entraînement

MAPPO, acteur gaussien partagé (sans identifiant d'agent, donc transférable à N fermes) + critique centralisé. 1 step RL = 1 année de culture, décisions séquentielles en ordre aléatoire, sous-steps de 122 jours. **400 épisodes** par politique.

lr	gamma	GAE lambda	clip	k_epochs	hidden	critic	entropie
3e-4	0,97	0,95	0,2	4	128	256	0,01 -> 0,001

Six objectifs de récompense, tout le reste identique :

politique	récompense
Profit	profit par ferme
Bal-20k ... Bal-400k	profit - lambda - pollution, lambda ∈ {20k, 100k, 200k, 400k}
Pollution	- pollution

Checkpoints en .pth et .onnx (normalisation des observations figée dans le graphe, export inference-only).

2. Protocole de test

Quatre conditions, obtenues en passant province et simple_spatial_data en paramètres de l'expérience marl au chargement - un seul fichier GAML, aucune édition entre les runs. Le script relit les deux valeurs dans la simulation en cours et refuse de produire un classeur si GAMA a ignoré un paramètre.

condition	province	carte	fermes
dtold_simple	Dong Thap old	simplifiée	10 ← entraînement
dtold_full	Dong Thap old	complète	748
dtnew_simple	Dong Thap	simplifiée	10
dtnew_full	Dong Thap	complète	992

Récompense fixée à **profit par ferme** pour toutes les politiques (la pollution est lue dans l'observation), actions **greedy**, même graine d'ordre de décision partout.

Chaque condition embarque ses **deux baselines déterministes sans IA** (MaxProfit = 100 % premium ; MinPollution = IPM + durable + AWD). C'est indispensable : un profit sur une carte inconnue n'est pas interprétable

seul, et la baseline change de signe d'une carte à l'autre.

3. Résultats

Profit par ferme (k€ / 25 ans)

politique	old simple (10)	old complet (748)	new simple (10)	new complet (992)
Profit	46,2	45,0	27,5	26,6
Bal-20k	31,6	27,6	-10,2	8,9
Bal-100k	23,6	13,6	5,9	7,9
Bal-400k	13,5	4,1	-19,6	2,0
Bal-200k	3,2	-6,1	-5,0	-6,7
Pollution	-5,4	-24,2	-30,6	-28,4
MaxProfit (sans IA)	4,7	11,1	-8,6	6,6
MinPollution (sans IA)	-110,0	-105,4	-121,4	-115,1

Le profit **global** n'est pas comparable entre cartes (10 vs 992 fermes) : seule cette colonne par ferme l'est.

Écart à la meilleure baseline sans IA de la même carte (k€/ferme)

C'est la mesure de transfert : > 0 = la politique bat une stratégie qui ignore l'état. Un ratio serait trompeur, la baseline étant négative sur `dtnew_simple`.

politique	old simple	old complet	new simple	new complet
Profit	+41,4	+33,9	+36,1	+20,0
Bal-100k	+18,9	+2,4	+14,5	+1,3
Bal-20k	+26,9	+16,4	-1,7	+2,2
Bal-400k	+8,8	-7,0	-11,1	-4,6
Bal-200k	-1,5	-17,3	+3,6	-13,3
Pollution	-10,2	-35,3	-22,0	-35,0

Pollution moyenne (bas = mieux)

politique	old simple	old complet	new simple	new complet
Bal-20k	0,0348	0,0055	0,0034	0,0058
Bal-100k	0,0451	0,0112	0,0077	0,0087
Pollution	0,0479	0,0131	0,0084	0,0110
MinPollution (100 % IPM)	0,0681	0,0108	0,0064	0,0090

4. Ce que ça montre

Une seule politique transfère. Profit bat la baseline sur les quatre cartes avec une marge franche (+20 à +41 k€/ferme). Bal-100k est la seule autre jamais négative, mais son avance s'effondre à pleine échelle (+18,9 -> +2,4). Les trois dernières perdent contre une stratégie constante sur trois cartes sur quatre.

L'acteur partagé généralise à l'échelle. Profit conserve **97 %** de son profit par ferme en passant de 10 à 748 fermes et de 10 à 992. La propriété visée par l'architecture - un acteur par fermier, sans identifiant - est vérifiée sur deux provinces.

La carte simplifiée surestime les performances. La baseline sans IA *s'améliore* avec l'échelle sur les deux provinces (4,7 -> 11,1 et -8,6 -> +6,6) pendant que les politiques se dégradent. Sur 10 fermes, quatre politiques semblent bonnes ; sur la carte réelle, une seule garde une marge solide. **Bon terrain d'entraînement, mauvais terrain de mesure.**

La récompense pollution ne pilotait rien. Sur les quatre cartes, la politique entraînée pour minimiser la pollution ne l'obtient jamais - et la baseline à 100 % d'IPM non plus. Celle qui atteint la pollution la plus basse partout est Bal-20k. Or l'IPM est le **seul** levier direct : la pollution n'est ajoutée que par un épandage (`Practices.gaml:481`). Le sweep lambda optimisait donc contre une cible hors de sa portée, ce qui explique les runs dégénérés bien mieux qu'un « lambda trop grand ».

Bal-200k est un entraînement raté, pas un effet de lambda. Il est l'anomalie aux deux échelles et sur les deux provinces (Bal-400k fait mieux que lui partout), et il ne bat pas la baseline sur sa propre carte d'entraînement.

5. Limites

- **Cartes complètes : 1 épisode** (45-60 min chacun), simplifiées : 3. Pas de barre d'erreur sur les deux conditions les plus coûteuses. Les écarts de Profit dépassent largement la variabilité observée sur cartes simples (~1 %), mais les marges de Bal-20k et Bal-100k à pleine échelle (+2,2 et +1,3) sont trop minces pour être départagées sans répétitions.
- **Le mécanisme de la pollution n'est pas établi.** L'hypothèse d'une boucle pollution -> pression parasitaire -> épandages (`Farms and Plots.gaml:445`) reste **non vérifiée** : `pesticide_count` existe sur la parcelle mais pas dans l'observation. L'exposer changerait la dimension d'observation et interdirait de réutiliser ces checkpoints.
- **Une seule graine par politique.** « Entraînement raté » pour Bal-200k reste une inférence à partir du comportement en évaluation, pas une comparaison multi-graines.

6. Reproduction

```
py eval_conditions.py --province "Dong Thap old" --simple --port 1001 --tag dtold_simple --episodes 3
py eval_conditions.py --province "Dong Thap old" --full --port 1001 --tag dtold_full
py eval_conditions.py --province "Dong Thap" --simple --port 1002 --tag dtnew_simple --episodes 3
py eval_conditions.py --province "Dong Thap" --full --port 1002 --tag dtnew_full
py plot_conditions.py
```

`--resume` reprend un classeur existant en ne rejouant que les politiques manquantes.

Artefacts : `eval_condition_<tag>.xlsx` (feuilles condition, legende, comparaison, synthese_fermiers, detail), `eval_conditions_synthesis.xlsx`, `eval_conditions_curves.png`.

Prérequis GAML : `Dong Thap old` doit fournir `plot_shapefile_simple.*` et `salinity_vulnerability_map_simple.tif`. Le renommage amont (`-simple -> _simple`) avait laissé cette province de côté, rendant la carte d'entraînement inchargeable.