

Mise à jour - effet de la graine, et non-transférabilité entre provinces

Complément à `rapport_transfert.md`, à partir de deux entraînements supplémentaires conçus comme des **contrôles** : chacun ne fait varier qu'une seule chose par rapport à un run existant, ce qui permet d'attribuer l'écart à cette variable et à rien d'autre.

run	ce qui change	tout le reste
<code>l200k_v2</code>	graine 0 -> 1	identique à Bal-200k
<code>dtnew_l20k</code>	carte d'entraînement -> Dong Thap	identique à Bal-20k

1. La graine change tout - lambda=200k, 400 épisodes, même config

mesure	seed 0	seed 1	rapport
éval greedy finale	34 967	119 488	x3,4
meilleure évaluation	34 967	128 655	x3,7
retour d'entraînement (10 % derniers ép.)	6 353	72 778	x11,5

Seule la graine diffère. lambda, hyperparamètres, carte, budget d'épisodes : identiques.

Trajectoire de la graine 1 (évaluation greedy, tous les 25 épisodes) :

ép.	24	49	74	99	124	149	174	199
	-244k	-252k	-57k	-77k	-13k	+3,5k	+30k	+21k
ép.	224	249	274	299	324	349	374	399
	+41k	+27k	+22k	+54k	+73k	+100k	+129k	+119k

Deux enseignements, au-delà de l'écart brut :

Le budget de 400 épisodes tronque l'entraînement. La graine 1 montait encore au 374■ épisode (+129k). Elle n'a pas convergé : elle a été arrêtée. La graine 0, elle, n'a jamais décollé - plafonnée à +35k.

La convergence est tardive et non monotone. Le zéro n'est franchi qu'au 149■ épisode, après quoi la courbe oscille entre +21k et +129k. À comparer avec lambda=20k sur la même carte, qui atteint son plateau dès le 74■ épisode et n'en bouge plus.

Confirmé en évaluation

L'écart ne se limite pas aux courbes d'entraînement. Les deux graines repassées dans `eval_conditions.py` (métrique du rapport de transfert : profit par ferme, actions greedy) :

carte	seed 0	seed 1 (v2)	baseline sans IA
DT old simplifiée (10)	3,2 -> -1,5	12,9 -> +8,2	+4,7
DT old complète (748)	-6,1 -> -17,3	4,9 -> -6,2	+11,1

(k€/ferme sur 25 ans ; après la flèche, l'écart à la baseline de la même carte.)

x4 sur la carte simplifiée, changement de signe sur la carte complète. La graine 0 est sous la baseline partout ; la graine 1 la dépasse sur carte simplifiée.

La conclusion opérationnelle ne bouge pas pour autant : sur la carte réelle, même la bonne graine reste **sous la baseline sans IA** (−6,2 k€/ferme). $\lambda=200k$ ne donne pas de politique utilisable à l'échelle réelle, quelle que soit la graine. La graine déplace l'ampleur de l'échec, pas sa nature - et c'est maintenant établi sur deux tirages, non plus un.

Conséquence directe sur le sweep lambda

Le sweep a donné **le même budget de 400 épisodes et une seule graine** à chaque valeur de lambda. Or les lambda élevés convergent nettement plus lentement. Les résultats du sweep confondent donc trois causes qu'on ne peut plus démêler a posteriori :

1. une mauvaise valeur de lambda,
2. un budget d'épisodes insuffisant pour ce lambda,
3. un tirage de graine défavorable.

Correction explicite de rapport_transfert.md : ce rapport conclut que « Bal-200k est un entraînement raté, pas un effet de lambda ». C'est faux. Le run d'origine n'a pas échoué - il a été arrêté trop tôt, avec une graine défavorable. La section interprétant le sweep lambda n'est pas concluante en l'état ; il faudrait 3 à 5 graines par valeur de lambda et un critère d'arrêt sur convergence plutôt qu'un budget fixe pour la rendre exploitable.

Ce point n'affecte **pas** le reste du rapport de transfert, qui repose sur les évaluations des politiques et non sur le sweep.

2. Une politique ne transfère pas d'une province à l'autre

Le contrôle

Bal-20k, appliquée à Dong Thap sans réentraînement, **perd de l'argent et fait moins bien qu'une stratégie constante**. La même récompense, entraînée directement sur cette carte, converge très haut :

Bal-20k	éval greedy finale	convergence
entraînée sur Dong Thap old	170 622	tardive
entraînée sur Dong Thap	367 429	dès l'ép. 124, plateau $\pm 0,6$ %

Confirmé en évaluation, et elle bat la meilleure politique transférée

Repassée dans eval_conditions.py, même métrique que le rapport de transfert :

carte	Bal-20k transférée	Bal-20k @DT	Profit transférée	baseline
DT simplifiée (10)	−10,2 -> −1,7	36,6 -> +45,2	27,5 -> +36,1	−8,6
DT complète (992)	8,9 -> +2,2	27,6 -> +21,0	26,6 -> +20,0	+6,6

(k€/ferme ; après la flèche, l'écart à la baseline de la même carte.)

La même récompense passe de **sous la baseline** (−1,7) à **+45,2 k€/ferme** par le seul fait d'avoir été entraînée sur la bonne carte - et dépasse Profit, la meilleure politique transférée, aux deux échelles.

Son mix d'actions n'est pas celui de la version transférée : 41 % d'AWD et 52 % de premium sur carte simplifiée, 49 % et 62 % sur carte complète. Elle exploite la carte au lieu de rejouer un réglage appris ailleurs.

Contrepartie : elle est moins robuste à l'échelle. Elle ne conserve que **75 %** de son profit par ferme de 10 à 992 fermes (36,6 -> 27,6), contre 97 % pour Profit sur les deux provinces. Son avance sur Profit fond donc presque entièrement à pleine échelle : +21,0 contre +20,0, soit 1 k€/ferme - un écart que ce protocole (un seul épisode sur carte complète) ne distingue pas du bruit. L'écart sur carte simplifiée (+45,2 contre +36,1, sur 3 épisodes) est lui bien réel.

Côté pollution, elle se situe entre les deux : 0,0056 puis 0,0071, contre 0,0034 / 0,0058 pour la transférée et 0,0066 / 0,0095 pour Profit. Elle a gagné en profit sans que $\lambda=20k$ lui fasse minimiser la pollution - cohérent avec l'axe pollution qui ne répond pas au levier IPM.

Ce n'est pas une carte plus difficile

L'objection évidente serait que Dong Thap est simplement plus dure. Les données disent l'inverse : le retour d'entraînement y démarre à **+204 567**, contre **-80 053** sur la carte d'origine. La nouvelle province est **plus favorable**, et pourtant la politique transférée y échoue. L'échec est donc bien imputable au transfert.

Sur les quatre cartes

Écart à la meilleure baseline sans IA de la **même** carte (k€/ferme ; > 0 = bat une stratégie qui ignore l'état) :

politique	old simple	old complet	new simple	new complet
Profit	+41,4	+33,9	+36,1	+20,0
Bal-100k	+18,9	+2,4	+14,5	+1,3
Bal-20k	+26,9	+16,4	-1,7	+2,2
Bal-400k	+8,8	-7,0	-11,1	-4,6
Bal-200k	-1,5	-17,3	+3,6	-13,3
Pollution	-10,2	-35,3	-22,0	-35,0

Cinq politiques sur six perdent leur avantage en changeant de province, trois passent sous la baseline. Seule Profit reste solidement positive partout - en perdant tout de même ~40 % de son profit par ferme (46,2 -> 27,5 k€).

Nuance importante : l'échelle transfère, la province non

Ces deux axes se comportent de façon opposée, et les confondre serait une erreur :

Profit	10 fermes	carte complète	conservé
Dong Thap old	46,2 k€	45,0 k€ (748)	97 %
Dong Thap	27,5 k€	26,6 k€ (992)	97 %

L'acteur partagé, sans identifiant d'agent, généralise presque parfaitement d'une dizaine à un millier de fermes - c'est la propriété visée par l'architecture, et elle est vérifiée sur deux provinces. Ce qui ne transfère pas, c'est le **changement de province** : sols, salinité et saturation du marché différent, et la politique n'a pas appris à s'y adapter.

Deux contrôles de plus - et le gain du réentraînement s'évapore à l'échelle

Profit et l'objectif Pollution ont été réentraînés sur Dong Thap à leur tour, mêmes hyperparamètres, graine 0, seule la province change.

Profit @DT récupère largement le coût du transfert sur carte simplifiée - et rien du tout sur la carte de déploiement :

Profit	10 fermes	992 fermes	conservé
transférée	27,5 -> +36,1	26,6 -> +20,0	97 %
@DT (réentraînée)	37,4 -> +45,9	26,1 -> +19,5	70 %
gain du réentraînement	+9,9	-0,5	

À 992 fermes les trois meilleures politiques tiennent dans 1,5 k€/ferme (Bal-20k @DT +21,0 ; Profit transférée +20,0 ; Profit @DT +19,5) - moins que ce qu'un seul épisode distingue.

Un point positif tout de même : rapportée à la baseline de chaque carte, Profit @DT (+45,9) fait **mieux que Profit sur sa propre carte d'origine** (+41,4). La perte de ~40 % constatée en transfert était bien un coût de transfert, pas un plafond de la nouvelle province.

La robustesse à l'échelle s'inverse selon l'origine de la politique :

politique	profit par ferme conservé, 10 fermes -> carte complète
Profit transférée (2 provinces)	97 %, 97 %
Bal-20k @DT	75 %
Profit @DT	70 %
Bal-200k v2	38 %


Les politiques **transférées** passent mieux à l'échelle que celles entraînées sur place, systématiquement sur quatre mesures. L'explication la plus économique serait un surajustement à la configuration des dix fermes d'entraînement - notamment aux dynamiques de saturation du marché premium, très différentes à 10 et à 992 - dont une politique venue d'ailleurs est par construction préservée. **Hypothèse non testée** : cohérente avec les quatre points, pas établie par eux.

Pollution @DT ferme définitivement la question de l'objectif environnemental :

échelle	profit/ferme	pollution	IPM
10 fermes	-13,1 -> -4,6	0,0084 (avant-dernière)	20 %
992 fermes	-27,2 -> -33,8	0,0109 (avant-dernière)	0 %

Entraînée sur place, sans transfert en jeu, elle reste sous la baseline sans IA et n'obtient la pollution la plus basse à aucune échelle - battue par Bal-20k (0,0058), par la baseline 100 % IPM (0,0090) et par Profit (0,0095), qui ne vise pourtant pas cet objectif.

Le détail décisif : **20 % d'IPM à 10 fermes, 0 % à 992**. La politique entraînée à minimiser la pollution abandonne le seul levier censé la réduire. Ce n'est pas un échec d'apprentissage mais son contraire - elle a correctement appris que, dans ce modèle, pulvériser moins ne réduit pas la pollution mesurée, et elle a réaffecté ses actions ailleurs (94 % d'AWD, 21 % de durable, 0 % de premium). Le défaut est dans la modélisation, pas dans l'algorithme.



Panneau du haut : profit global en évaluation greedy. Traits pleins = Dong Thap old, comparables entre eux ; pointillés = Dong Thap, dont l'économie de base diffère (la stratégie constante sans IA y vaut $-8,6$ k€/ferme contre $+4,7$ sur Dong Thap old) et qui ne sont donc jamais comparables aux précédents. En dessous, le retour d'entraînement de chaque run, chacun à son échelle puisque les récompenses diffèrent.

3. Ce qu'il faut en retenir

1. **Un seul run ne prouve rien sur ce modèle.** Un facteur 3,7 entre deux graines du même réglage suffit à inverser un classement. Toute comparaison entre configurations exige plusieurs graines.
2. **Un budget fixe fausse la comparaison** entre réglages dont les vitesses de convergence diffèrent d'un facteur 4.
3. **Un modèle s'évalue sur la carte où il servira.** L'entraînement sur carte simplifiée reste valide, mais la mesure doit se faire sur la carte cible : la carte simplifiée surestime nettement les performances, et la baseline sans IA elle-même s'y comporte différemment ($+4,7$ vs $+11,1$ k€/ferme selon l'échelle).
4. **Réentraîner sur place gagne beaucoup sur petite carte, et rien à l'échelle réelle.** Bal-20k y passe de sous la baseline à $+45,2$ k€/ferme en 124 épisodes ; mais pour Profit le gain est de $+9,9$ k€/ferme sur 10 fermes et de $-0,5$ sur 992. Un gain mesuré sur carte simplifiée ne préjuge pas du gain en déploiement.
5. **L'objectif pollution est inexploitable en l'état.** Établi sur quatre cartes, deux provinces, deux échelles, en transfert **comme en entraînement direct** - et la politique qui lui est dédiée finit par abandonner l'IPM, le seul levier disponible. C'est un défaut de modélisation, pas d'apprentissage.

4. Limites

- **n = 2 graines, sur une seule valeur de lambda.** Ça démontre que l'effet existe et qu'il est massif ; ça ne quantifie pas la variance générale, et ne dit pas si $\lambda=20k$ est aussi sensible.
- **Un seul réentraînement sur la nouvelle province**, avec $\lambda=20k$. Les autres récompenses n'y ont pas été testées.
- **Cartes complètes : un seul épisode d'évaluation** (45 à 60 min l'épisode). Les écarts de Profit dépassent largement la variabilité observée sur cartes simples (~1 %), mais les marges de Bal-20k et Bal-100k à pleine échelle (+2,2 et +1,3) sont trop minces pour être départagées sans répétitions.
- Le greedy_return de l'entraînement utilise la comptabilité global_profit de GAMA, celui du tableau des quatre cartes somme les récompenses par ferme. **Les valeurs absolues des sections 1 et 2 ne sont pas comparables entre elles** ; chaque section est cohérente avec sa propre métrique.

5. Reproduction

```

py train_mappo.py config_mappo3_l200k_v2.yaml          # seed 1, Dong Thap old (port 1001)
py train_mappo.py config_mappo3_dtnew_l20k.yaml        # lambda=20k, Dong Thap (port 1002)
py train_mappo.py config_mappo3_dtnew_profit.yaml      # profit, Dong Thap (port 1001)
py train_mappo.py config_mappo3_dtnew_pollution.yaml # pollution, Dong Thap (port 1002)
py plot_learning.py                                     # figure des 10 runs

# evaluation, un tag dédié par modèle pour ne pas toucher aux 4 classeurs du rapport
py eval_conditions.py --province "Dong Thap" --simple --port 1001 \
  --tag dtnew_profit_simple --episodes 3 --no-baselines --only "Profit @DT"
py eval_conditions.py --province "Dong Thap" --full --port 1002 \
  --tag dtnew_pollution_full --episodes 1 --no-baselines --only "Pollution @DT"

```

province et simple_spatial_data sont désormais des clés optionnelles de la section gama : des configs YAML : absentes, le comportement est celui d'avant. La carte est relue dans la simulation au démarrage, et le run échoue immédiatement si GAMA a ignoré un paramètre - sans quoi 400 épisodes pourraient tourner sur la mauvaise province sans que rien ne le signale.

Figure : `report/fig_apprentissage_mappo3.png`.